

Биоинформатика: «текстовая» и «структурная». Базы данных



Чугунов Антон

Лаборатория моделирования биомолекулярных систем

<http://model.nmr.ru>

Институт биоорганической химии РАН

<http://ibch.ru>

Долгопрудный, МФТИ, 20 сентября 2018 г.

План лекции


1. Что такое биоинформатика?
2. Большие базы «сухой биологии»
3. Последовательности генов
4. Аминокислотные последовательности
5. Структуры белков
6. Выравнивание последовательностей
7. Поиск последовательностей в базах
8. Филогенетические деревья



Что такое «биоинформатика»?

БИОлогия + ИНФОРМАТИКА: “computer science” в биологии

Структурная биоинформатика




- Молекулярное моделирование
- Дизайн белков
- Драг-дизайн

«Текстовая» биоинформатика

- «Биологические тексты»
- Компьютерная геномика
- Молекулярная эволюция

Алгоритмическая биоинформатика



- Моделирование сложных систем
- Генные сети
- Алгоритмы биоинформатики
- и т.д.

Разновидности биоинформатики

- Клиническая биоинформатика
- Структурная геномика
- Функциональная геномика
- Фармакогеномика
- Клиническая протеомика
- Функциональная протеомика
- Структурная протеомика
- Другие «омики»

...и любые направления современной биологии и медицины, где необходимо систематизировать и анализировать данные биохимических экспериментов

Немного истории

1202

1925

1951

1953

1957

1967

1970

1977

1990

1995

1996

1999

2006

1202



Леонардо Пизанский (Фибоначчи) публикует книгу «Liber abaci», которая содержит решение задачи о размножении кроликов.

1925



Вито Вольтерра и Альфред Лотка предложили математическую модель совместного существования «хищник-жертва».

1951



Лайнус Полинг открыл Белковую α -спираль, что ознаменовало рождение новой науки — структурной биологии.

1953



Джеймс Уотсон и Френсис Крик открыли структуру ДНК в форме двух комплементарных цепей, образующих двойную спираль.

1953



Первый расчёт состояния идеализированной молекулярной системы методом Монте Карло.

1957



Первый расчёт молекулярной динамики идеализированной молекулярной системы.

1967



Создание метода самосогласованных силовых полей — основы современной молекулярной динамики.

1970



Первый алгоритм выравнивания последовательностей.

1977



Секвенирован геном бактериофага ϕ X-174 — первый полный геном; первый случай использования «метода дробовика».

1977



Первый расчёт молекулярной динамики белковой глобулы.

1990




Запущен международный проект «Геном человека».

1995



Секвенирован первый бактериальный геном (*Haemophilus influenzae*).

1996



Полная последовательность генома дрожжей *Saccharomyces cerevisiae* (первый геном эукариот).

1999



Корпорация Celera закончила секвенирование генома *Drosophila melanogaster* — самого «популярного» объекта в молекулярной генетике.

2006



Публикация полной последовательности последней человеческой хромосомы: фактическое завершение проекта «Геном человека».

Большие базы «сухой биологии»


Genbank

www.ncbi.nlm.nih.gov/genbank



- «Склад» генетических данных
- Сотни миллионов последовательностей генов
- Полные геномы

последовательностей




Uniprot

www.uniprot.org



- «Склад» а/к последовательностей
- Курируемый и некурируемый разделы
- Подробные аннотации




Protein Data Bank

www.rcsb.org



- «Склад» 3D-структур белков
- ≈140 тыс. структур
- Десятки тысяч разных белков
- Многих структур пока нет!




bit.ly/BM-InSilico

Генетические последовательности

Источник генетических данных — геномные проекты, в том числе знаменитый «Геном человека».


Прогресс достигнут за счет методик секвенирования ДНК.



Метод «терминаторов» Сэнгера

Секвенирование «нового поколения» (NextGen)

- Фрагментация (shotgun)
- Регистрация включения нуклеотидов
- Биоинформатическая «сборка»




Нанопоровое секвенирование


Аминокислотные последовательности

- Химический метод. Фрагментирование полипептида химическими реагентами с последующей идентификацией фрагментов
- Автоматическое секвенирование (метод Эдмана). Последовательная деградация белка с N-конца (реакция с фенилизотиоцианатом; ФИТЦ) + идентификация
- Ферментативный метод. Отщепление а.о. с помощью карбоксипептидазы + идентификация
- Физический метод: масс-спектрометрия. MS/MS анализ и Peptide mass fingerprinting

Метод Эдмана



Протеомика: MS-анализ + фингерпринт



Формат файла FASTA

```
>gi|5524211|gb|AAD44166.1| cytochrome b [Elephas maximus maximus]  
LCLYTHIGRNIYYGSYLYSETWNTGIMLLLITMATAFMGYVLPWGQMSFWGATVITNLFSAIPYIGTNLV  
EWIWGGFSVDKATLNRFFAFHFILPFTMVALAGVHLTFLHETGSNNPLGLTSDSDKIPFHPYYTIKDFLG  
LLILILLLLLLLALLSPDMLGDPDNHMPADPLNTPLHIKPEWYFLFAYAILRSVPNKLGGVLALFLSIVIL  
GLMPFLHTSKHRSMMLRPLSQALFWTLTMDLLTLTWIGSQPVEYPYTIIGQMASILYFSIILAFLPIAGX  
IENY
```

>SEQUENCE_1

```
MTEITAAMVKELRESTGAGMMDCKNALSETNGDFDKAVQLLREKGLGKAAKKADRLAAEG  
LVSVKVSDDFTIAAMRPSYLSYEDLDMTFVENEYKALVAELEKENEERRRLKDPNKPEHK  
IPQFASRKQLSDAILKEAEEKIKEELKAQGKPEKIWDNIIPGKMNSFIADNSQLDSKLT  
MGQFYVMDDKKTVEQVIAEKEKEFGGKIKIVEFICFEVGEGLEKKTEDFAAEVAAQL
```

>SEQUENCE_2

```
SATVSEINSETDFVAKNDQFIALTKDTTAHIQSNSLQSVEELHSSTINGVKFEEYLKSQI  
ATIGENLVVRRFATLKAGANGVVNGYIHTNGRVGVVIAAACDSAEVASKSRDLLRQICMH
```



Пространственные структуры белков

Рентгеноструктурный анализ




-  получение кристалла
-  получение дифракционной картины
-  расчет распределения электронной плотности
-  определение атомарной модели

ЯМР-Спектроскопия



Криоэлектронная микроскопия



Нобелевская премия по химии 2017

Формат файла pdb

```

HEADER      EXTRACELLULAR MATRIX                      22-JAN-98   1A3I
TITLE       X-RAY CRYSTALLOGRAPHIC DETERMINATION OF A COLLAGEN-LIKE
TITLE       2 PEPTIDE WITH THE REPEATING SEQUENCE (PRO-PRO-GLY)
...
EXPDTA      X-RAY DIFFRACTION
AUTHOR      R.Z.KRAMER,L.VITAGLIANO,J.BELLA,R.BERISIO,L.MAZZARELLA,
AUTHOR      2 B.BRODSKY,A.ZAGARI,H.M.BERMAN
...
REMARK 350  BIOMOLECULE: 1
REMARK 350  APPLY THE FOLLOWING TO CHAINS: A, B, C
REMARK 350    BIOMT1    1  1.000000  0.000000  0.000000          0.00000
REMARK 350    BIOMT2    1  0.000000  1.000000  0.000000          0.00000
...
SEQRES      1  A      9  PRO PRO GLY PRO PRO GLY PRO PRO GLY
SEQRES      1  B      6  PRO PRO GLY PRO PRO GLY
SEQRES      1  C      6  PRO PRO GLY PRO PRO GLY
...
ATOM        1  N      PRO A      1          8.316  21.206  21.530  1.00 17.44      N
ATOM        2  CA     PRO A      1          7.608  20.729  20.336  1.00 17.44      C
ATOM        3  C      PRO A      1          8.487  20.707  19.092  1.00 17.44      C
ATOM        4  O      PRO A      1          9.466  21.457  19.005  1.00 17.44      O
ATOM        5  CB     PRO A      1          6.460  21.723  20.211  1.00 22.26      C
...
HETATM     130  C      ACY      401          3.682  22.541  11.236  1.00 21.19      C
HETATM     131  O      ACY      401          2.807  23.097  10.553  1.00 21.19      O
HETATM     132  OXT    ACY      401          4.306  23.101  12.291  1.00 21.19      O
...

```

Формат файла pdb: секция ATOM

[illegible]

Выравнивание последовательностей

Выравнивание – это определение соответствия между аминокислотными остатками (для белков) или нуклеотидами (для ДНК/РНК) в последовательностях

- Парное выравнивание: поиск сходных участков двух последовательностей
- Множественное выравнивание: поиск консервативных участков в наборе последовательностей

воОбРажение
сОдеРжание-

воОбраЖЕНИЕ
-сОдерЖание

воОбРаЖЕНИЕ
сОдеР-Жание

GTaTAGTc-Ta
GT-TAGTagTc

GT-A-TAGTCta
GTtAgTAGTC--

$N = 184\,756$. $N_{20} = 1,38 \times 10^{11}$. $N_{100} = 9,05 \times 10^{58}$

```

AAB24882 TYHMCQFHC RYVNNHSGEKL YECNERSKAFSCPSHLQCHKRRQIG EKT HEHNQCGKAFFPT 60
AAB24881 -----YECNQCGKAFAQHSSLKCHYRTHIG EKP YECNQCGKAFSK 40
          *****: .***: * *:*** * :*****.:* *****..

AAB24882 PSHLQYHERTHTG EKP YECNQCGQAFKKCSLLQRHKRTHTG EKP YECNQCGKAFAQ- 116
AAB24881 HSHLQCHKRTHTG EKP YECNQCGKAFSQHGLLQRHKRTHTG EKP YMNVINMVKPLHNS 98
          *****:*****:***:***.: .*****: *.:

```

Выравнивание: пример

ERWINRUDOLFJOSEFALEXANDERSCHRODINGER																																		
ERWIN SCHRODINGER	E											E			E					E													E	
	R			R															R							R							R	
		W																																
			I																													I		
				N												N																N		
																												S						
																													C					
																														H				
		R			R																						R			R				R
																															O			
																															D			
			I																													I		
				N																													N	
																																	G	
E												E			E					E						E						E		
R		R																									R			R				R

«Расстояние» между последовательностями

1. Идентичность последовательностей. Доля идентичных а.о., стоящих в тех же позициях в последовательностях А и В

Seq1: FTFTALILLA Идентичность = 80%

Seq2: FEFTALVLLA

2. Расстояние по Хеммингу. Количество несовпадающих позиций

Seq1: FTFTALILLA $R_{\text{Хемминг}} = 2$

Seq2: FEFTALVLLA

3. Расстояние по Левенштайну (редакционное расстояние).


Минимальное число преобразований, переводящих одну последовательность в другую

Seq1: FTFT-LILLA $R_{\text{ред}} = 3$

Seq2: FEFTALVLLA


Требуется учитывать природу а/к замен!

Физико-химические свойства а/к остатков



Вероятность замены а/к остатков

Suggested Amino Acid Substitutions
 solvent exposed ($SEA^a > 30 \text{ \AA}^2$) / interior ($SEA^a < 10 \text{ \AA}^2$)



Amino acids connected by a solid line can be substituted with 95% confidence
 (D. Bordo and P. Argos, J. Mol. Biol. 217(1991)721-729)


^aSEA=solvent exposed area

Матрицы замены а/к остатков

Матрица BLOSUM62

	C	S	T	P	A	G	N	D	E	Q	H	R	K	M	I	L	V	F	Y	W	
C	9																				C
S	-1	4																			S
T	-1	1	5																		T
P	-3	-1	-1	7																	P
A	0	1	0	-1	4																A
G	-3	0	-2	-2	0	6															G
N	-3	1	0	-2	-2	0	6														N
D	-3	0	-1	-1	-2	-1	1	6													D
E	-4	0	-1	-1	-1	-2	0	2	5												E
Q	-3	0	-1	-1	-1	-2	0	0	2	5											Q
H	-3	-1	-2	-2	-2	-2	1	-1	0	0	8										H
R	-3	-1	-1	-2	-1	-2	0	-2	0	1	0	5									R
K	-3	0	-1	-1	-1	-2	0	-1	1	1	-1	2	5								K
M	-1	-1	-1	-2	-1	-3	-2	-3	-2	0	-2	-1	-1	5							M
I	-1	-2	-1	-3	-1	-4	-3	-3	-3	-3	-3	-3	-3	1	4						I
L	-1	-2	-1	-3	-1	-4	-3	-4	-3	-2	-3	-2	-2	2	2	4					L
V	-1	-2	0	-2	0	-3	-3	-3	-2	-2	-3	-3	-2	1	3	1	4				V
F	-2	-2	-2	-4	-2	-3	-3	-3	-3	-3	-1	-3	-3	0	0	0	-1	6			F
Y	-2	-2	-2	-3	-2	-3	-2	-3	-2	-1	2	-2	-2	-1	-1	-1	-1	3	7		Y
W	-2	-3	-2	-4	-3	-2	-4	-4	-3	-2	-2	-3	-3	-1	-3	-2	-3	1	2	11	W
	C	S	T	P	A	G	N	D	E	Q	H	R	K	M	I	L	V	F	Y	W	


Множественное выравнивание



Поиск «гомологов»

BLAST (англ. **B**asic **L**ocal **A**lignment **S**earch **T**ool) – семейство компьютерных программ для поиска гомологов белков или нуклеиновых кислот, для которых известна первичная структура или её фрагмент.

Идея — поиск в последовательности похожих или совпадающих «слов» максимальной длины.



Поиск «гомологов»: BLAST

blast.ncbi.nlm.nih.gov NCBI Blast: Protein Sequence (64 letters)

NIH U.S. National Library of Medicine NCBI National Center for Biotechnology Information Sign in to NCBI

BLAST® » **blastp suite** » RID-U6ACNS5B015 Home Recent Results Saved Strategies Help

[Edit and Resubmit](#) [Save Search Strategies](#) [Formatting options](#) [Download](#) [YouTube](#) [How to read this page](#) [Blast report description](#)

Job title: Protein Sequence (64 letters)

RID U6ACNS5B015 (Expires on 09-21 13:01 pm)

Query ID lcl|Query_22961
Description None
Molecule type amino acid
Query Length 64

Database Name nr
Description All non-redundant GenBank CDS translations+PDB+SwissProt+PIR+PRF excluding environmental samples from WGS projects
Program BLASTP 2.8.0+ [Citation](#)

Other reports: [Search Summary](#) [Taxonomy reports](#) [Distance tree of results](#) [Multiple alignment](#) [MSA viewer](#)

New Analyze your query with [SmartBLAST](#)

Graphic Summary

[Show Conserved Domains](#)

Putative conserved domains have been detected, click on the image below for detailed results.

Query seq. I K G G Y I V D D V N C T Y F C G R N H Y C N E E C T K L K G E S G Y C O W A S P Y G N A C Y C Y K L P D H V R T K G P O R C R

Specific hits **Toxin_3**

Superfamilies **Toxin_3 superfamily**

Distribution of the top 100 Blast Hits on 100 subject sequences

Mouse over to see the title, click to show alignments

Color key for alignment scores

Score Range	Color
<40	Black
40-50	Blue
50-80	Green
80-200	Pink
>=200	Red

1 10 20 30 40 50 60

query

Questions/comments

Поиск «гомологов»: FASTA

www.ebi.ac.uk FASTA Results Summary

FASTA

Protein Nucleotide Genomes Proteomes Whole Genome Shotgun Web services Also in this section Feedback Share

Tools > Sequence Similarity Searching > FASTA

Results for job fasta-l20180920-060158-0488-25458550-p2m

Summary Table Tool Output Visual Output Functional Predictions Submission Details

Selection:

Apply to selection:

Annotations:

Alignments:

Entries:
 in
 fasta
 format

Align.	DB:ID	Source	Length	Score (Bits)	Identities %	Positives %	E()
☒ 1	SP:SCX2_LEIQH	Alpha-mammal toxin Lqh2 OS=Leiurus quinquestriatus hebraeus OX=6884 PE=1 SV=1 <i>Cross-references and related information in:</i> ► Bioactive molecules ► Literature ► Samples & ontologies ► Protein families ► Protein sequences	64	134.7	100.0	100.0	1.4E-29
☒ 2	TR:D5HR56_LEIQH	Neurotoxin 2 OS=Leiurus quinquestriatus hebraeus OX=6884 PE=3 SV=1 <i>Cross-references and related information in:</i> ► Nucleotide sequences ► Literature ► Samples & ontologies ► Protein families ► Protein sequences	85	133.0	100.0	100.0	6.3E-29
☒ 3	SP:SCX2_ANDAU	Alpha-mammal toxin AaH2 OS=Androctonus australis OX=6858 PE=1 SV=3 <i>Cross-references and related information in:</i> ► Bioactive molecules ► Nucleotide sequences ► Literature ► Samples & ontologies ► Protein families	85	132.7	98.4	100.0	7.5E-29

Молекулярная эволюция

БАКТЕРИИ



АРХЕИ




ЭУКАРИОТЫ




Грамположительные бактерии

Chloroflexales

Энтамебы Слизевики Животные



Карл Вёзе (1928-2012)




Выводы

1. Без биоинформатики современная биология невозможна
2. Продукт биоинформатики — онлайн-базы данных — уже воспринимается как «воздух»
3. Очень многие исследования в современной биологии можно делать «всухую», без капли реактива

Биомолекула



Торжество
компьютерных
методов:
предсказание
строения белков




Молекулярная
динамика
биомолекул. История
полувековой давности



Драг-дизайн: как в
современном мире
создаются новые
лекарства



454-секвенирование
ДНК



На заре молекулярной
графики



Ловля бабочек, или
чем структурная
геномика поможет
биологии


Биомолекула



Невидимая граница:
где сталкиваются
«нано» и «био»




Зрительный родопсин —
рецептор, реагирующий
на свет



Недоупорядоченные
белки



Рецепторы в активной
форме



Антимикробные
пептиды — возможная
альтернатива
традиционным
антибиотикам




Миллисекундный
барьер взят!

Биомолекула



Калиевый канал
in silico



Компьютерные игры в
молекулярную
биофизику
биологических мембран



Пространственно-
временное
моделирование в
биологии



Рецептор
“нетрадиционной
ориентации”



Липидный фундамент
жизни



Биохаеры:
молекулярная биология
в стиле «сделай сам»

Спасибо за внимание!

