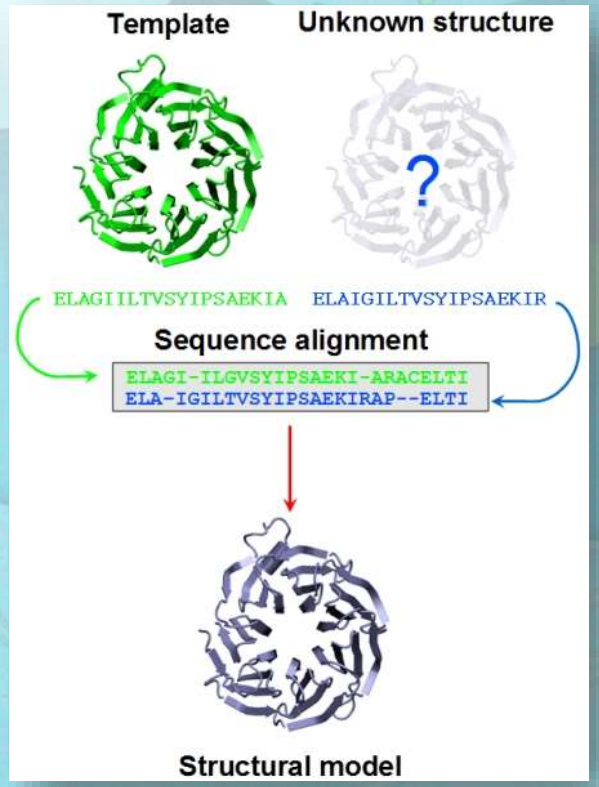

Предсказание структуры белков на основе гомологии

Чугунов Антон
Группа анализа структуры мембранных белков *in silico*
https://www.ibch.ru/structure/groups/giamps

Долгопрудный, МФТИ
19 октября 2023 г.

К вопросу о «белковой вселенной»

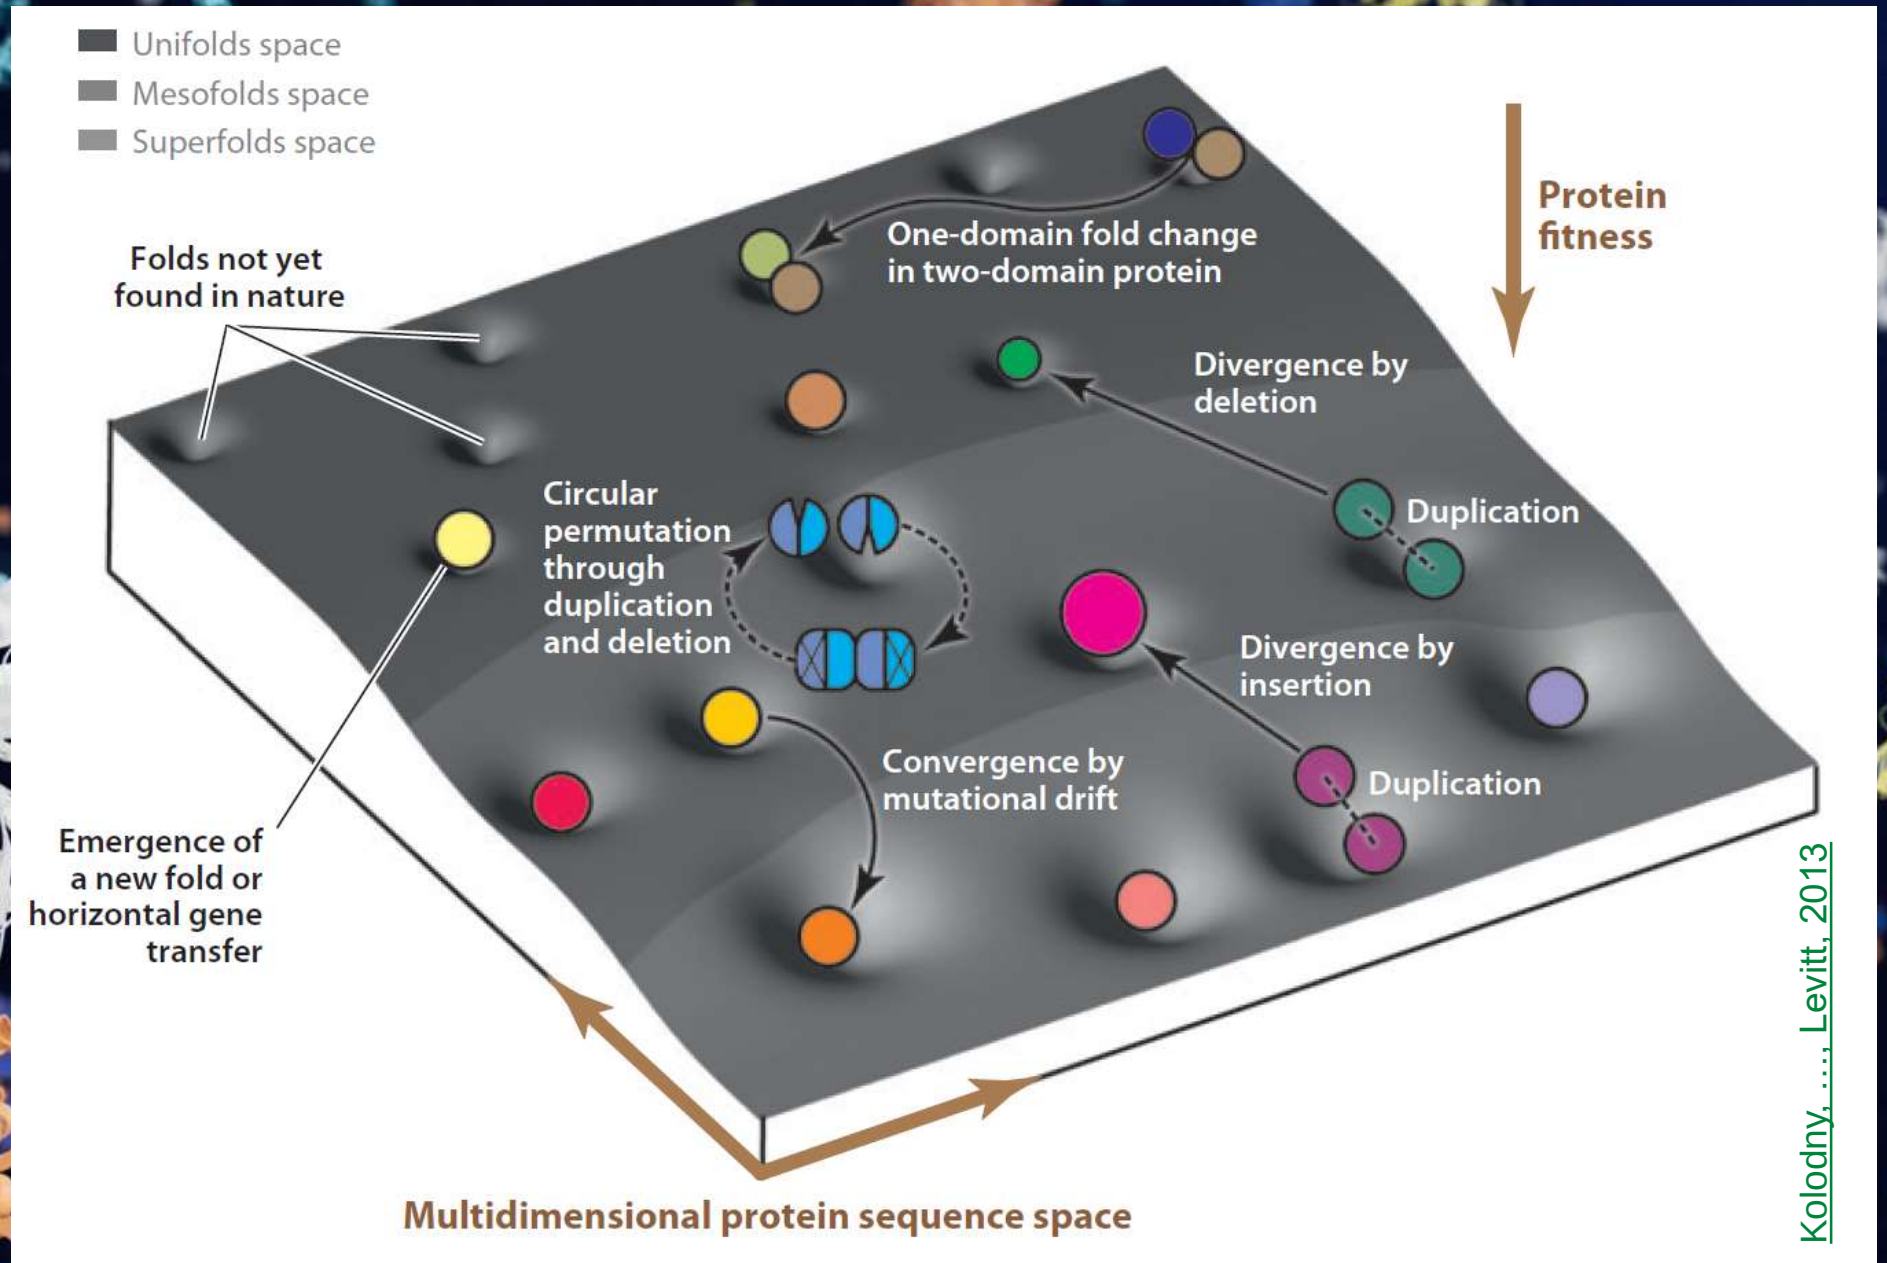

Kolodny, …, Levitt, 2013

План доклада

1. Введение
2. Что можно извлечь из последовательности белка?
   1. Вторичная структура
   2. «Шаблоны» для моделирования
   3. Структурные мотивы
   4. Вариабельность, амфифильность
3. Что такое фолдинг и как его моделировать?
   1. Физические подходы
   2. Моделирование на основе гомологии
   3. Методики и типичные ошибки
4. Оценка качества получаемых моделей
5. Применение пространственных моделей белков
6. Выводы

Для чего нужна структура белков?

1. «Догма» молекулярной биофизики:

2. Дизайн новых лекарственных препаратов с учётом структуры белка-«мишени»
3. Биотехнология: химическая, пищевая, энергетическая отрасли — «потребители» информации о структуре белков

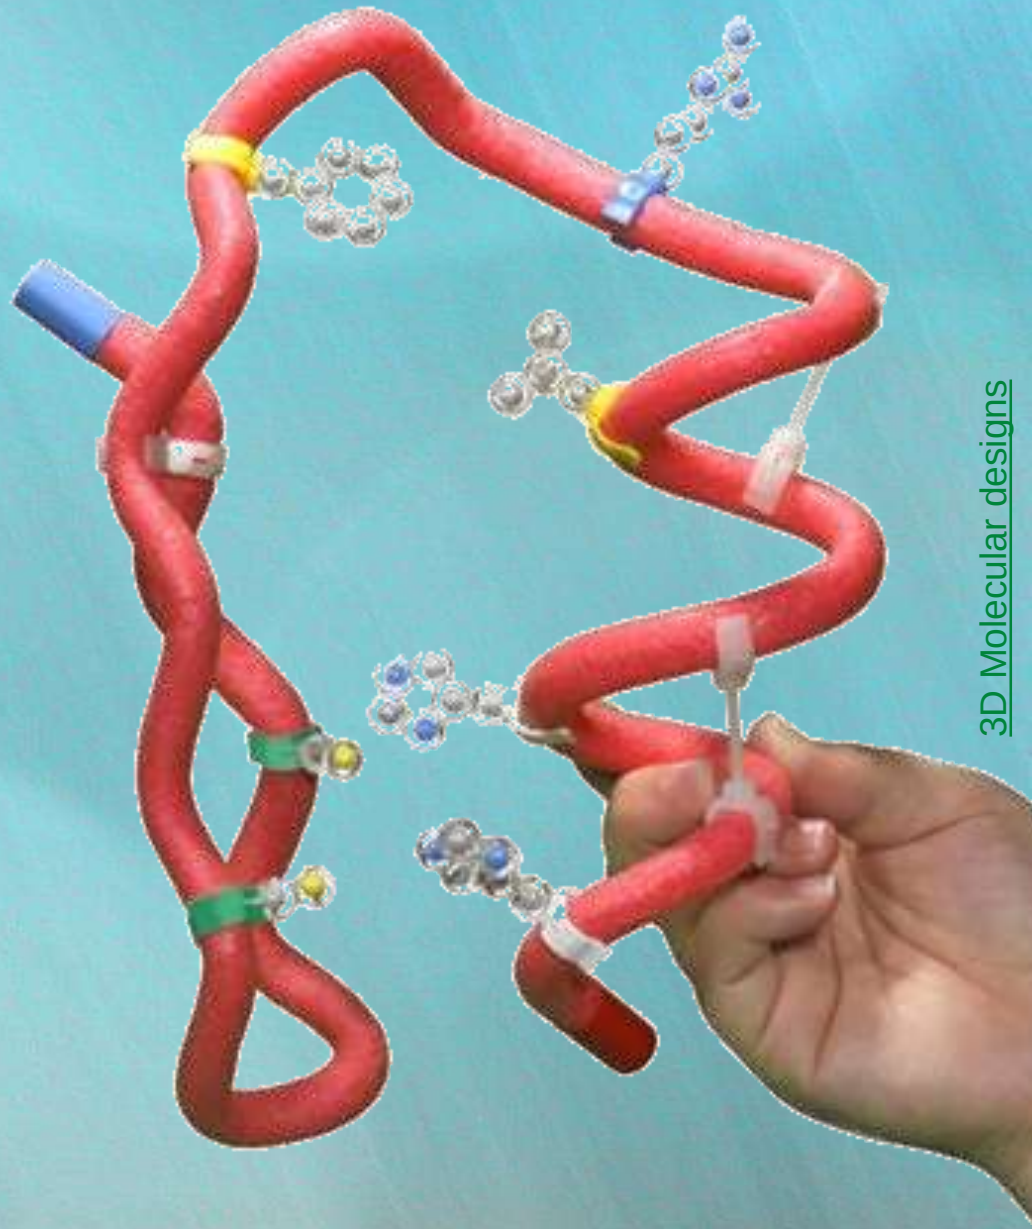

3D Molecular designs

Структурные исследования белков:

фундаментальный и прикладной интерес

- Структуру определить намного сложнее, чем последовательность
  Число последовательностей: 570K / 251M (*Swiss-Prot / TrEMBL*)
  Число 3D-структур: 210K (*PDB*)
- Возможности методов экспериментального определения структуры ограничены
  - *РСА:* сложность получения кристалла
  - *ЯМР:* ограниченный размер молекулы, проблемы анализа спектров
  - *Крио-ЭМ:* новый, дорогой метод
- Структурные исследования: высокие затраты денег и ресурсов

Возможный выход: теоретическое предсказание структуры

☑ Высокая скорость, низкая трудоёмкость

☒ Не всегда удовлетворительное «качество» моделей

AlphaFold

Полуэмпирические методы (ab initio) — 10 атомов

Молекулярная динамика — $10^{3\div4}$ атомов

Сопоставительное моделирование — $10^{4\div5}$ атомов

Компьютерный анализ а/к последовательностей

Анализируют только а/к последовательность белка, пренебрегают взаимодействием между боковыми группами

Что можно делать:

- Вычислять физико-химические параметры
- Предсказывать продукты расщепления протеазами
- Гидрофобные, гидрофильные участки: например, трансмембранные сегменты
- Пост-трансляционные модификации
- Функциональные домены, принадлежность к функциональным семействам

...и где:

- ExPASy – протеомика
  http://www.expasy.ch
- European Bioinformatic Institute (EBI) – многочисленные базы и инструменты
  https://www.ebi.ac.uk/services
- CBS Prediction Servers – локализация, пост-трансляционные модификации...
  http://www.cbs.dtu.dk/services

Предсказание свойств белка

ProtParam

- Молекулярная масса
- Аминокислотный состав
- Теоретическая pI
- Коэффициент экстинкции при 280 нм
- Период полураспада в организме
- Алифатический индекс
- Гидрофильность / гидрофобность

PeptideMass

Можно учитывать или не учитывать посттрансляционные модификации для белков из Swiss-Prot, а также полиморфизмы и изоформы

Предсказание ТМ-сегментов

- Десятки а/к шкал
- Топология межсегментных участков
- Различные алгоритмы
- Десятки серверов

Поиск доменов

Домен – независимая единица в белке:
структурно, функционально, эволюционно

- Как правило, каждый домен играет свою роль в функции белка (связывает ион или ДНК, содержит активный сайт и т.п.)
- Только небольшая часть известных доменов была изучена экспериментально, остальные описаны как сходные части гомологичных белков
- Очень сложно четко определить домен и его границы => существует много подходов и различных доменных коллекций:
  - 1980-е: PROSITE: ручная выборка паттернов в белках, определяющих функцию
  - 1987: доменный профайл (Gribskov):
  - position specific scoring schema – это вероятность для каждой аминокислоты находиться в данной позиции домена
  - начало 1990-х: BLOCKs, PRINTs, Prodom…
  - PfamA: коллекция профайлов, курированная вручную (сейчас также использует HMM)
- Сервера:
  - InterProScan: http://www.ebi.ac.uk/InterProScan
  - CD (Conserved Domain) server (NCBI): http://www.ncbi.nlm.nih.gov/Structure/cdd
  - Pfscan: http://hits.isb-sib.ch/cgi-bin/PFSCAN

Поиск доменов

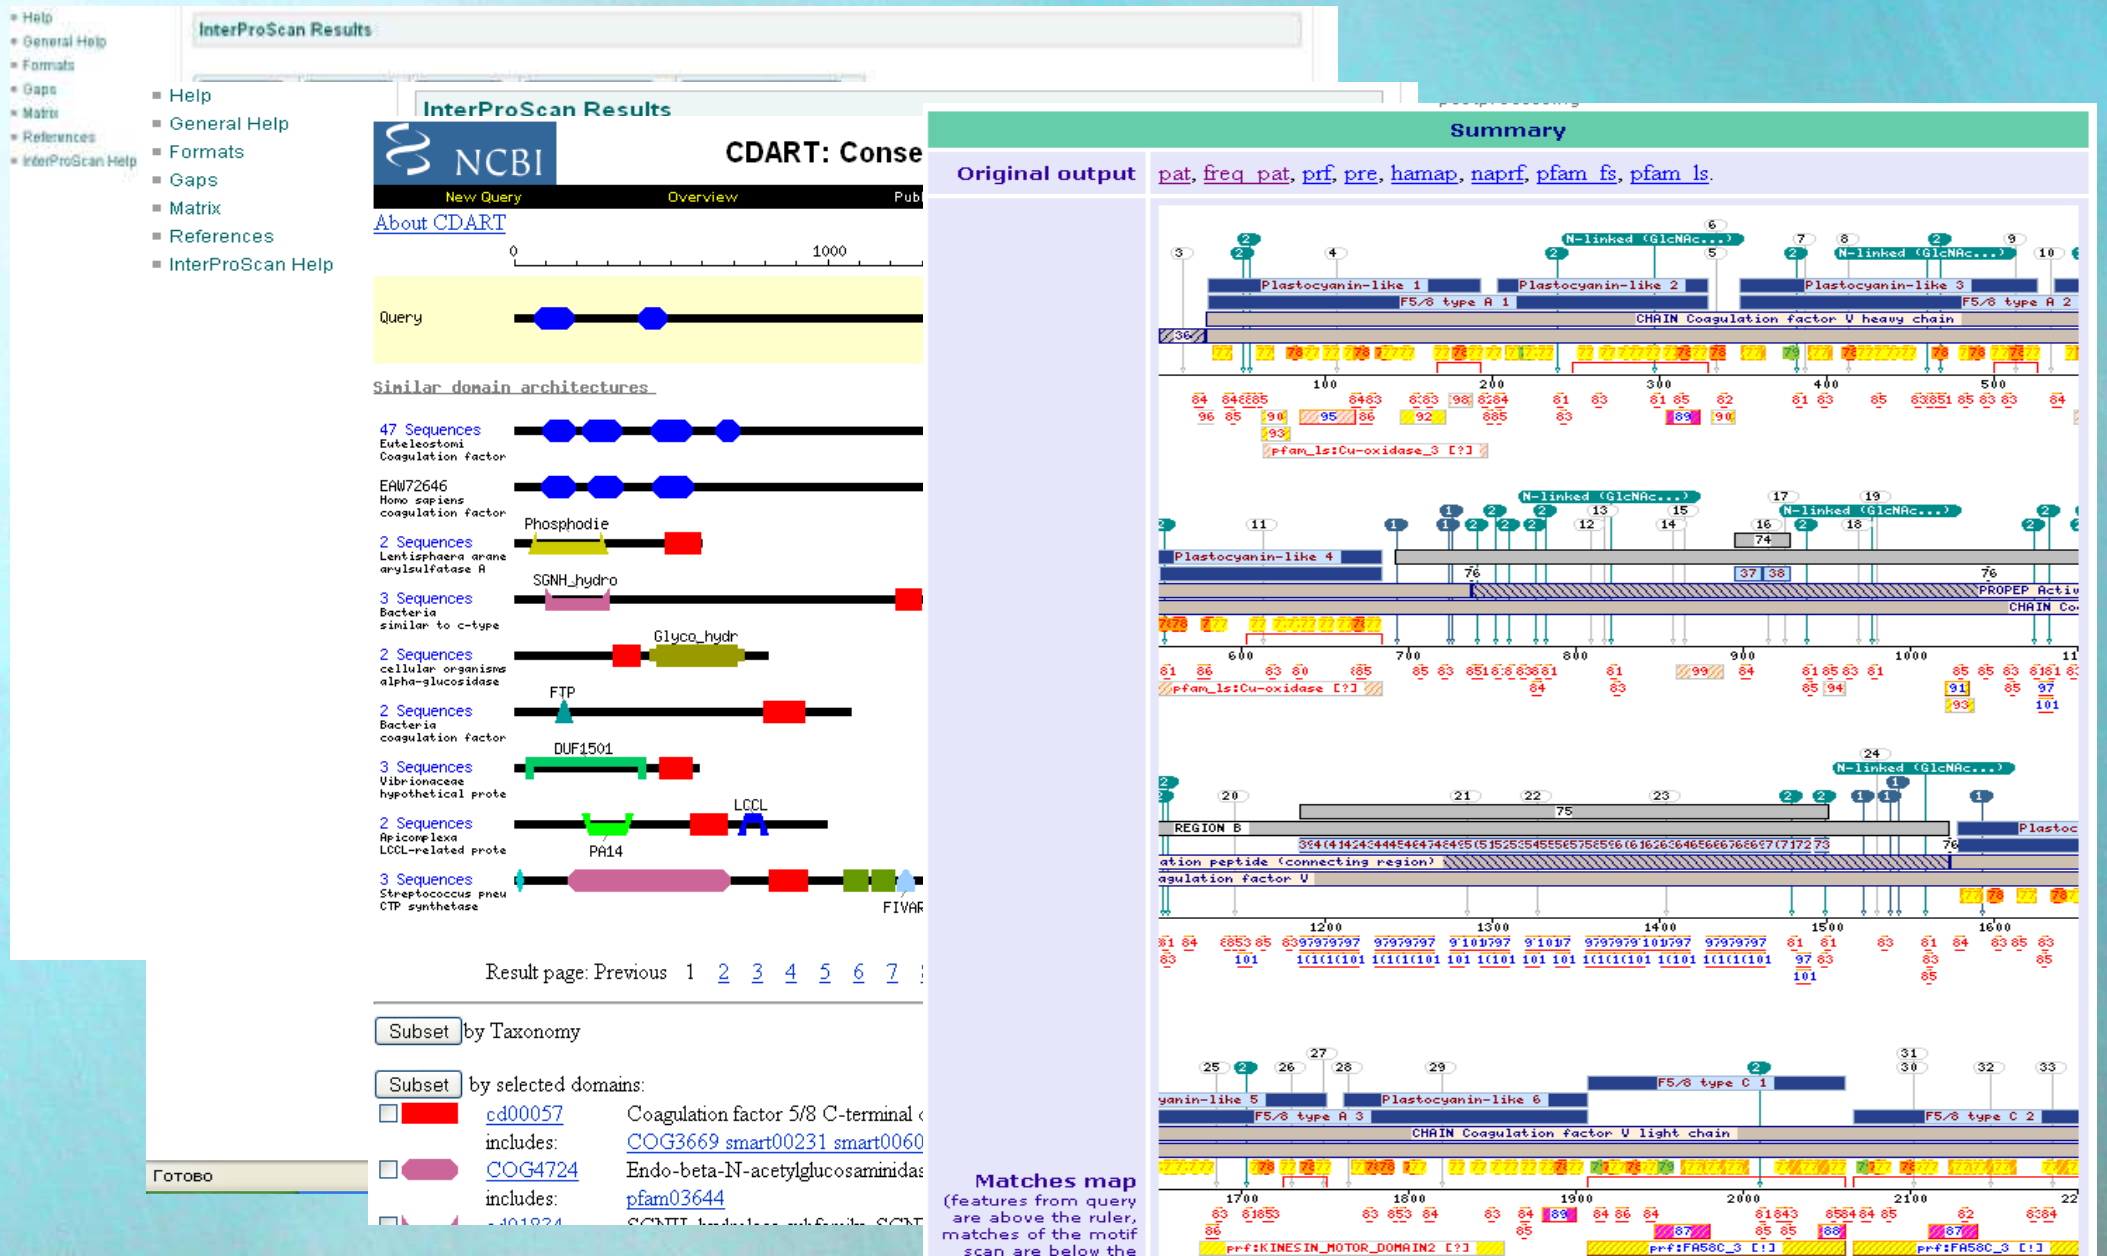

Предсказание вторичной структуры

- Начало 1990-х
- На Web – очень много программ
- α-спиральные участки, β-листы, неупорядоченные участки
- Точность предсказания ~75%

```
PSIPRED PREDICTION RESULTS

Key

Conf: Confidence (0=low, 9=high)
Pred: Predicted secondary structure (H=helix, E=strand, C=coil)
  AA: Target sequence


# PSIPRED HFORMAT (PSIPRED V2.5 by David Jones)

Conf: 987768742244664265311588652002212788898785421444666432233763
Pred: CCCCCCCCCCCCCCCCCCCCCCCCCCCCCHHHHCCCCCCHHHHHHCCCCCCCCCCCCCCCC
  AA: MTERRVPFSLLRGPSWDPFRDWYPHSRLFDQAFGLPRLPEEWSQWLGGSSWPGYVRPLPP
              10        20        30        40        50        60


Conf: 000373112633342100220898312588795399999827998756599998998999
Pred: CCCCCCCCCCCCCCCCCHHHCCCCCEEEEECCCEEEEEEECCCCCHHHEEEEEECCEEEE
  AA: AAIESPAVAAPAYSRALSRQLSSGVSEIRHTADRWRVSLDVNHFAPDELTVKTKDGVVEI
              70        80        90       100       110       120


Conf: 998010000188758889998762889885762876657985999971578875447427
Pred: EEEECCHHHCCCEEEEEEEEEEECCCCCCHHHEEEEECCCCEEEEEEECCCCCCCCCCEE
  AA: TGKHEERQDEHGYISRCFTRKYTLPPGVDPTQVSSSLSPEGTLTVEAPMPKLATQSNEIT
             130       140       150       160       170       180


Conf: 757414875446766443431203 9
Pred: EEEEECCCCCCCCCCCCCCCCHHHCC
  AA: IPVTFESRAQLGGPEAAKSDETAAK
             190       200


Calculate PostScript, PDF and JPEG graphical output for this result using:
http://bioinf2.cs.ucl.ac.uk/cgi-bin/psipred/gra/nph-view2.cgi?id=05471106883edf08.psi
```

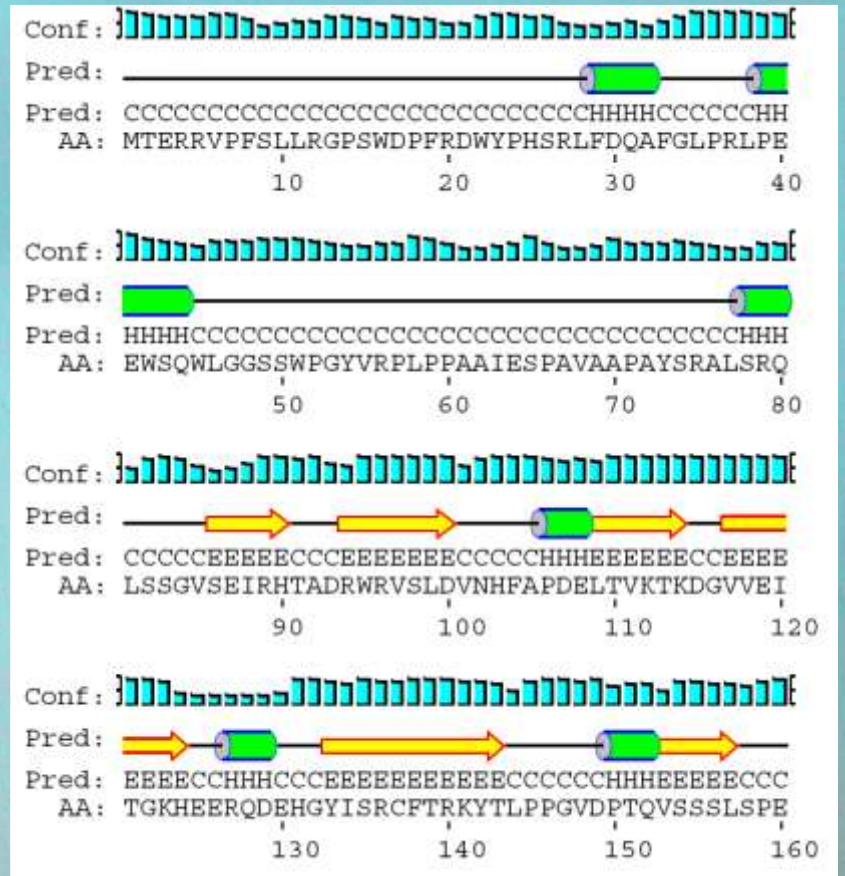

Как промоделировать фолдинг?

Фолдинг — это сворачивание биомакромолекул из развёрнутой конформации в «нативную» (естественную) форму.

- *Термодинамика фолдинга:* уникальность нативной структуры.
- *Кинетика фолдинга:* парадокс Левинталя, ~10^{143} возможных конформаций!

Моделирование «пути» фолдинга — одна из важнейших неразрешённых задач молекулярной биофизики!

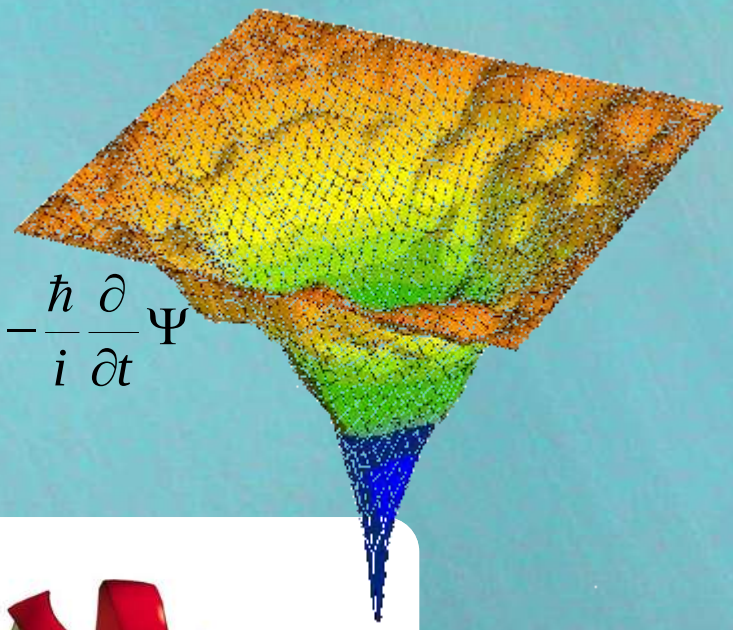

Варианты моделирования структуры молекул:

$$-\frac{\hbar^2}{2m}\Delta\Psi + E\Psi = -\frac{\hbar}{i}\frac{\partial}{\partial t}\Psi$$

- Квантовая химия;
- Эмпирические «физические» подходы («силовые поля»);
- Учёт эволюционного родства (моделирование по гомологии)

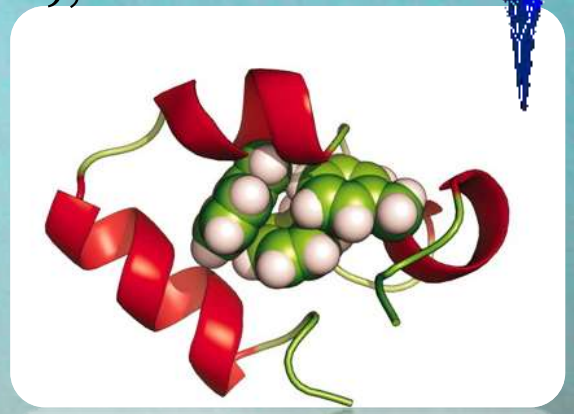

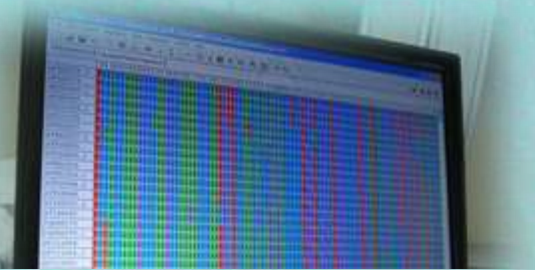

Эмпирические «физические» подходы
(“ab initio” предсказания)

***“Ab initio”* — «из первых принципов» —** в предсказании не используются априорные знания о структуре белка́, а только физические модели, основанные на эмпирических «силовых полях».

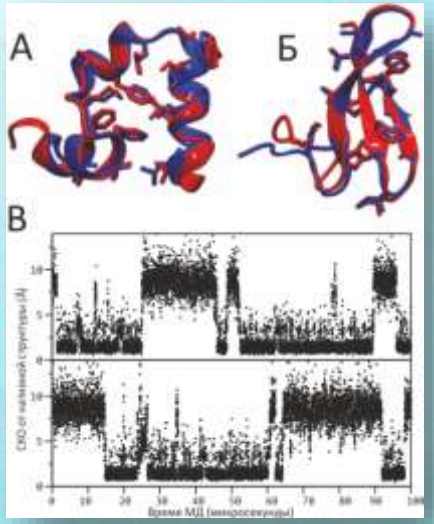

- Миллисекундная МД (10^{-3} с): виллин, FiP35 — несколько актов сворачивания / разворачивания
- Более крупный белок БПТИ: фолдинга в МД достичь не удалось, но конформационные переходы вблизи нативной структуры соответствуют данным ЯМР
- Первая МД БПТИ: несколько *пико*секунд (10^{-12} с)

McCammon & Karplus (1977). *Nature* 267, 585

Дальнейшие упрощения:

- Упрощённые энергетические функции
- Упрощённое представление молекул
- Имитация «зародышей структуры» — «сборка мозаики»

Rosetta @ Home — предсказание белков длиной <150 а.к.о.

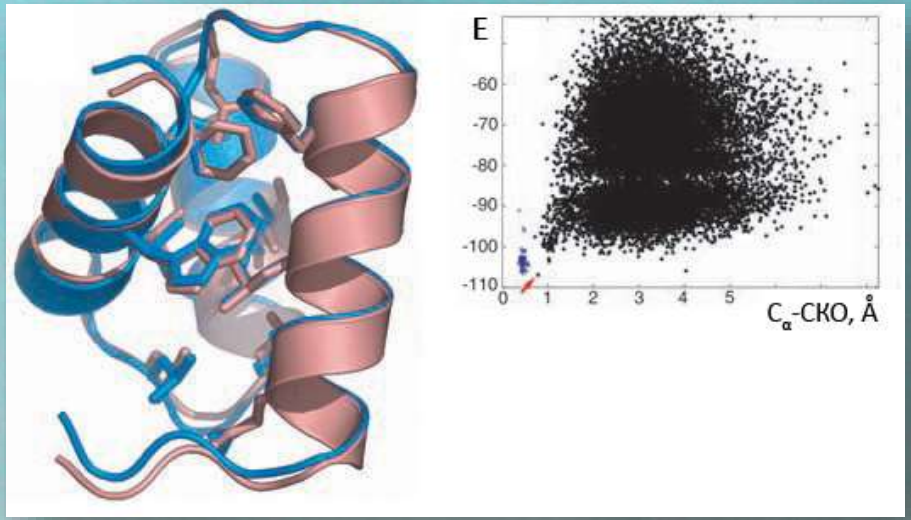

Что такое гомология

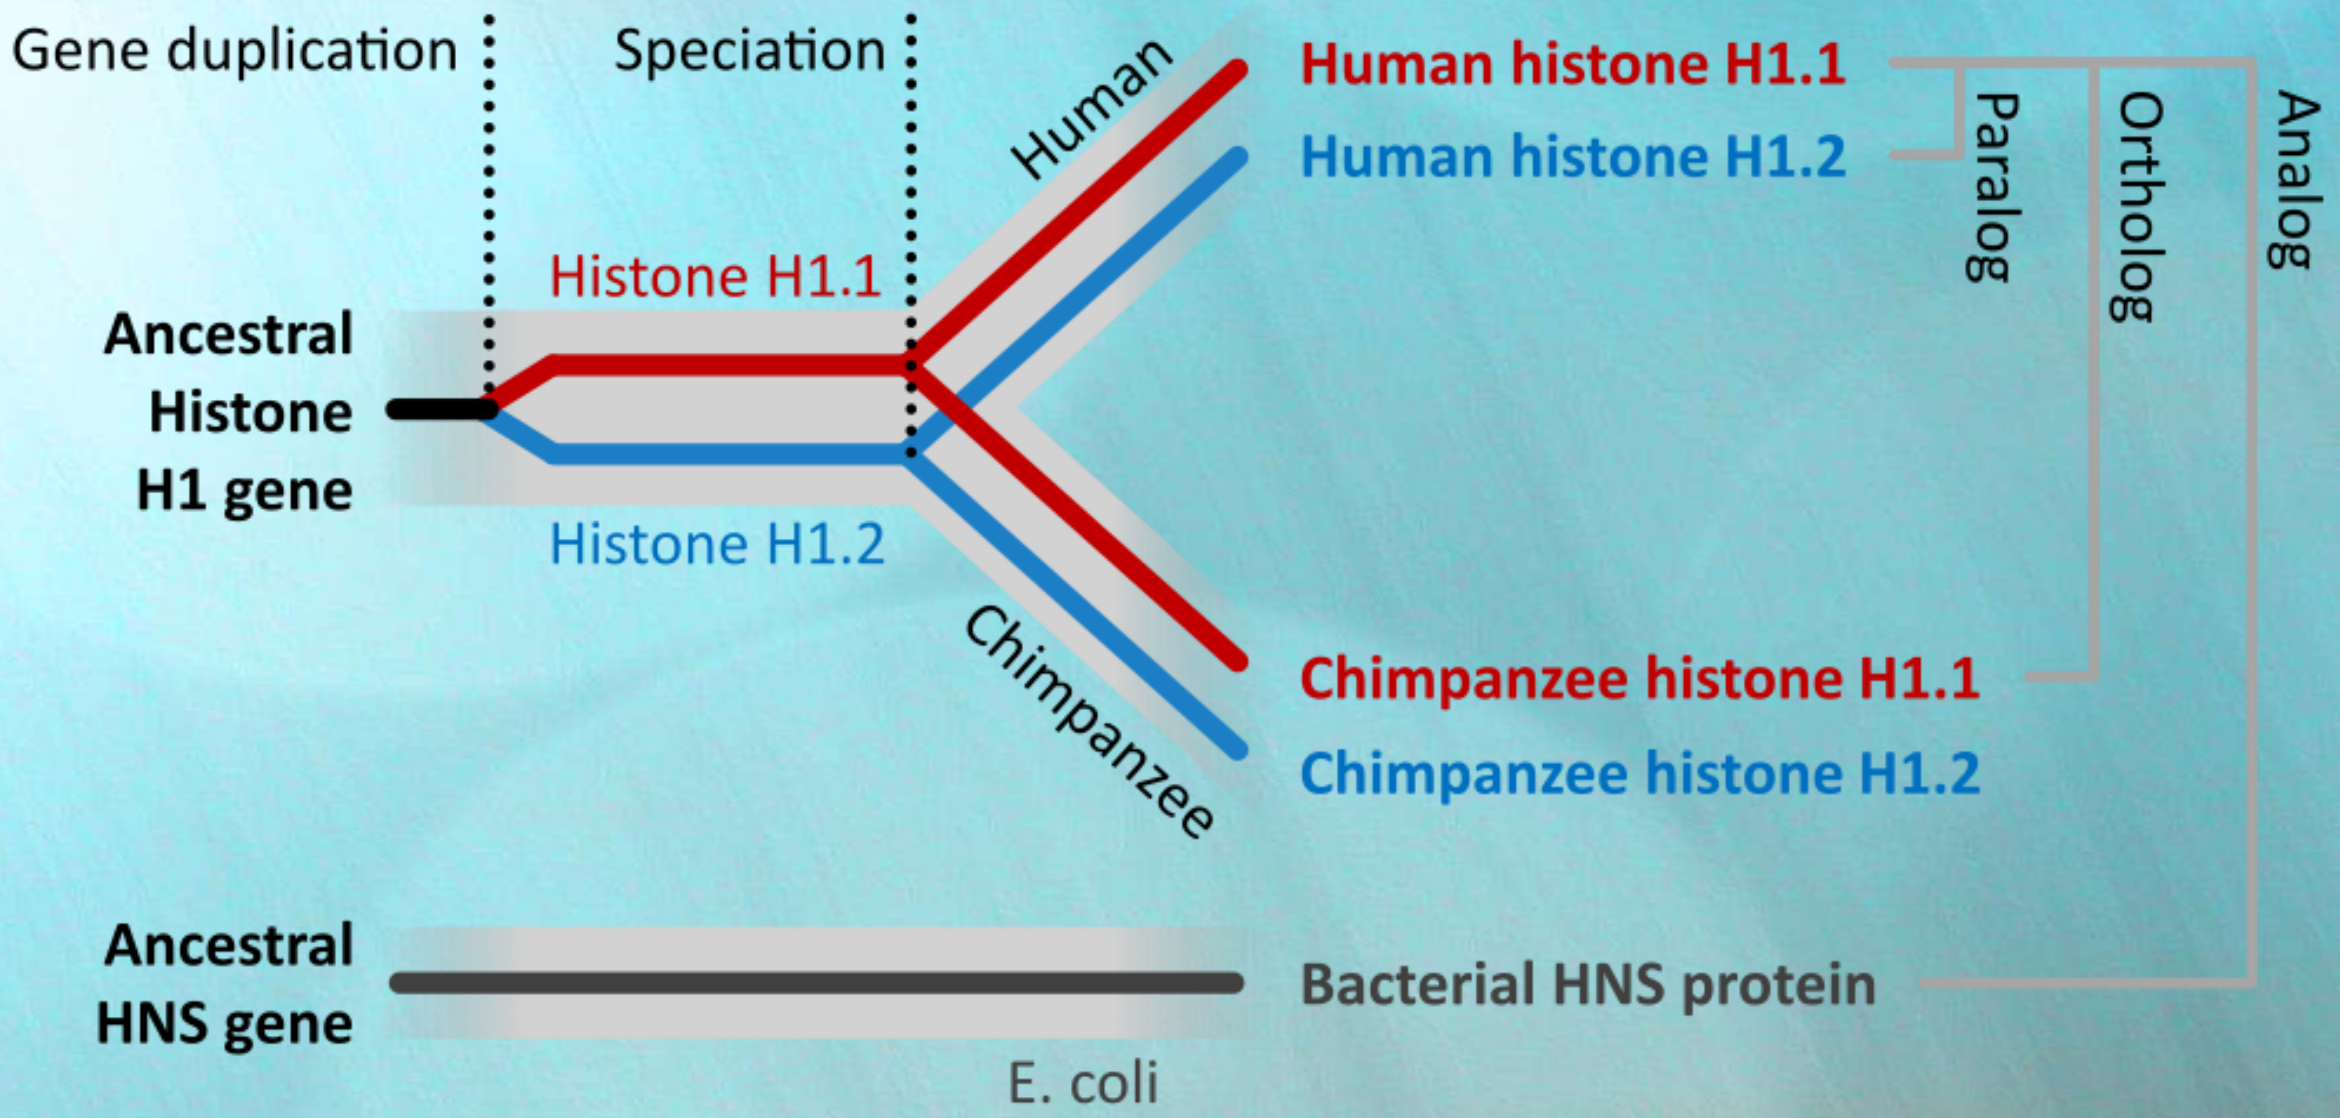

Сопоставительное моделирование

(моделирование на основе гомологии)

- «Вселенная» белков ограничена: ≈3500 структурных семейств, ≈1000 типов укладки
- Белк*и* — продукт эволюции; предполагаемый механизм — дупликация генов и дивергенция функций
- Эмпирическое наблюдение: при идентичности последовательностей >30% структуры белков весьма схожи

- Для каждого второго белка существует структурный гомолог
- При оптимальной стратегии достаточно определить всего 16000 структур, чтобы >90% белков можно было промоделировать по гомологии

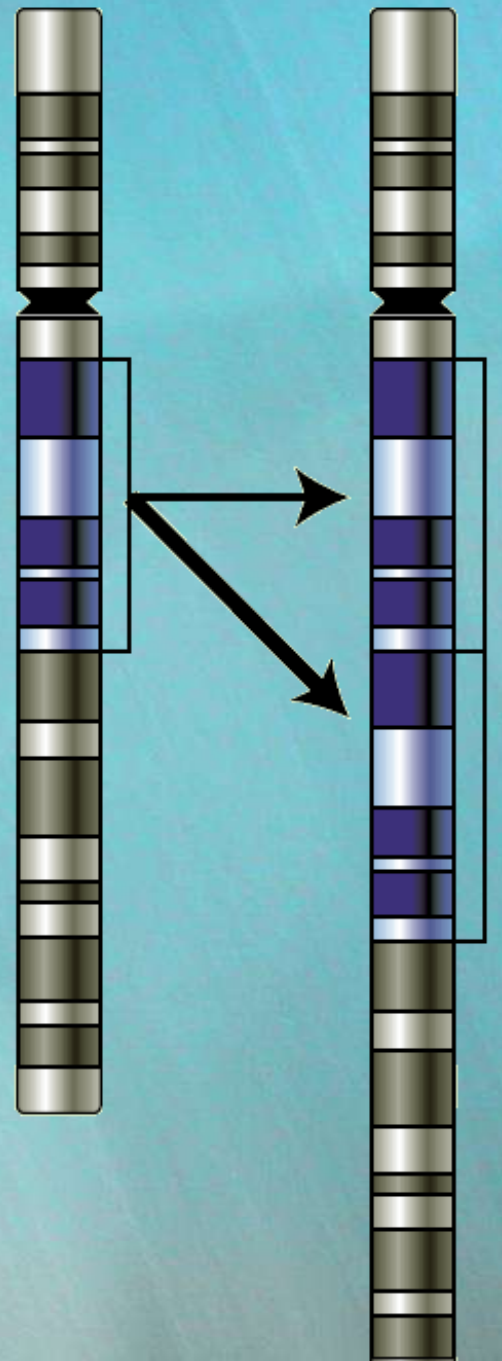

Моделирование по гомологии

Цель:

построить 3D-модель белка с неизвестной структурой, на основе сходства последовательностей с белком, структура которого определена

Почему это возможно?

1. Небольшие изменения в а/к последовательности белка приводят к небольшим изменениям в 3D-структуре
2. 3D-структура более консервативна в семействе белков, чем а/к последовательность
3. Гомология по крайней мере с одним белком, структура которого известна, определяется для >50% всех известных а/к последовательностей

Зачем это нужно?

Число известных а/к последовательностей ~100 млн.

Моделирование по гомологии может быть применено к миллионам.
Экспериментально пространственная структура определена только для <100K белков

Моделирование по гомологии: общая схема

Белок с неизвестной структурой

Идентификация типа укладки (поиск шаблона)

Выравнивание а/к последовательностей модели и шаблона

Построение модели (боковые цепи, петли)

Оптимизация модели

Оценка качества модели

Использование модели

Последовательность модели (hMTR1A) ...PSWLASALACVLIFTIVVDILGNLLVILSVYRNKKLRNAGN...

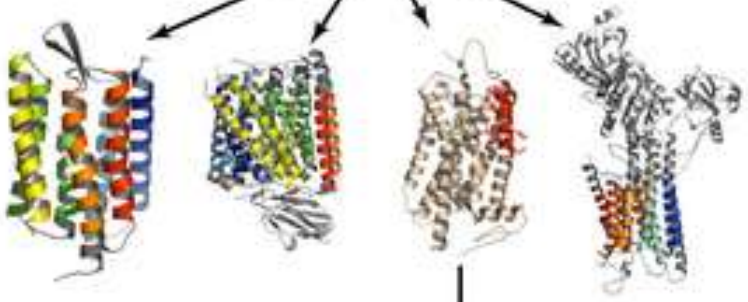

```
Модель (hMTR1A)     ...PSWLASALACVLIFTIVVDILGNLLVILSVYRNKKLRNAGN...
Гомолог (hMTR1B)    ...PPWVAPALSAVLIVTTAVDVVGNLLVILSVLRNRKLRNAGN...
Гомолог (mMTR1A)    ...PSWLASTLAFILIFTIVVDILGNLLVILSVYRNKKLRNSGN...
Шаблон (bOPSD)      ...EPWQFSMLAAYMFLLIVLGFPINFLTLYVTVQHKKLRTPLN...
Шаблон (hADRB2)     ...DEVWVVGMGIVMSLIVLAIVFGNVLVITAIAKFERLQTVTN...
                        :.  : .     .  *.*.:    : .:*:.  *
```

Трёхмерная модель структуры мембранного рецептора

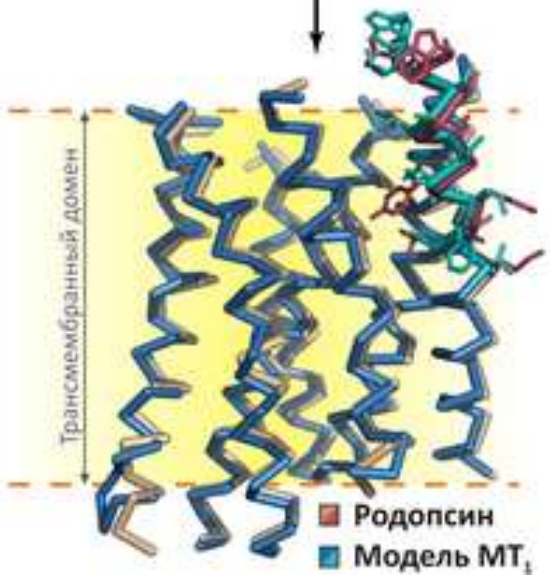

Выбор шаблона для моделирования

Работа с последовательностями:

1. Парное сравнивание моделируемой последовательности с каждой последовательностью из базы данных — FASTA, BLAST

2. Сравнение сразу нескольких последовательностей — PSI-BLAST, CLUSTAL

3. «Протягивание» последовательности через библиотеку «профилей» 3D-структур (идентификация отдалённых гомологов)

Факторы, влияющие на выбор шаблона:

1. **Высокая идентичность последовательностей**
2. Белки принадлежат к одному подсемейству
3. Качество экспериментальной структуры (разрешение или количество ограничений на аминокислотный остаток)

% идентичности	Качество выравнивания
>40%	Почти всегда высокое
30–40%	Ошибочно выровненные участки
<30%	«Сумеречная зона»

Методы построения моделей

ПО для моделирования

- Сборка модели из «твердых тел» — COMPOSER
- Моделирование путем сопоставления сегментов — SEGMOD
- Моделирование на основе пространственных ограничений — MODELLER

Интернет-серверы и базы

- Swiss-Model
- Swiss-Model Repository
- ModBase
- AlphaFold Protein Structure Database

Моделирование петель

- *ab initio*
- Поиск в базах данных

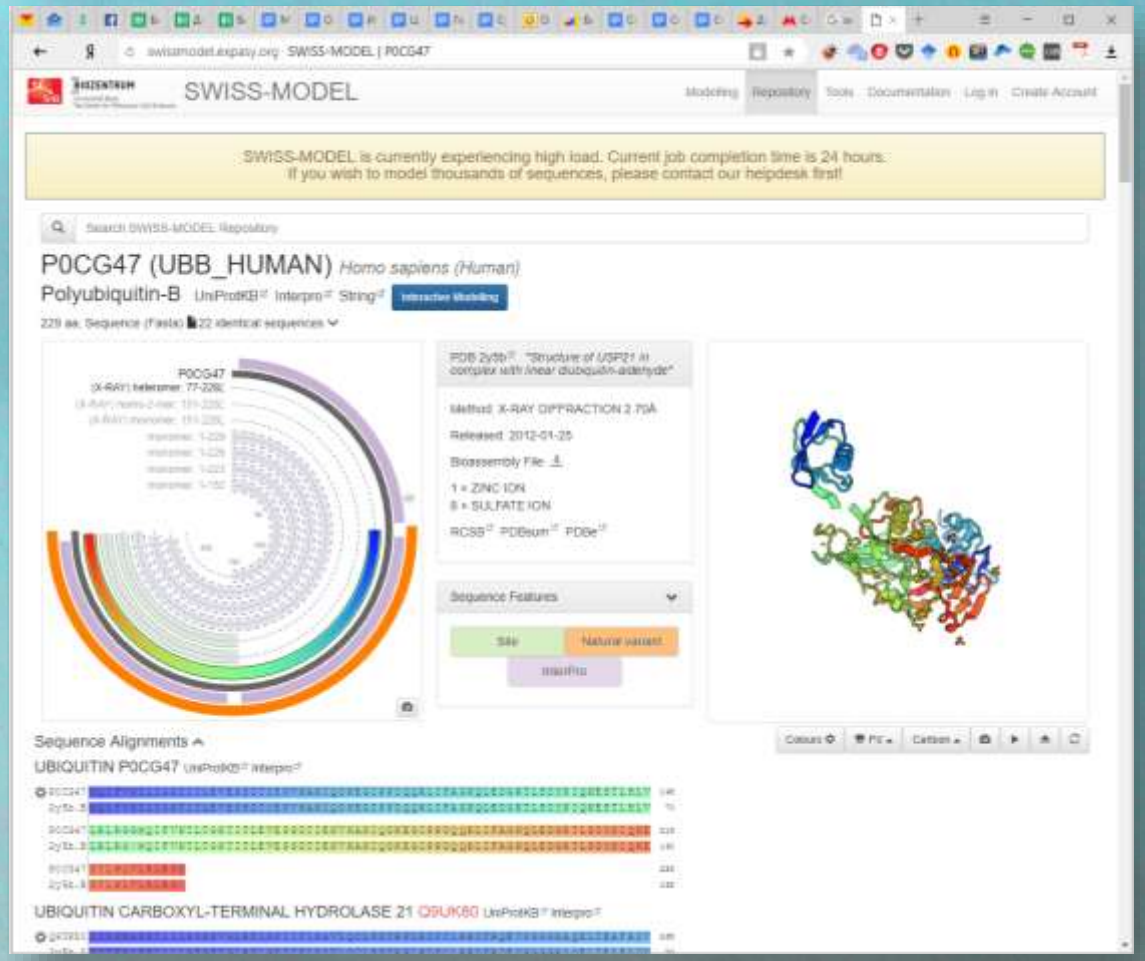

Типичные ошибки построения моделей

1. Ошибки в структуре боковых цепей

Мышиный белок, связывающий ретиноевую кислоту.

Тонкая линия — кристалл, толстая линия — модель, пунктир — шаблон

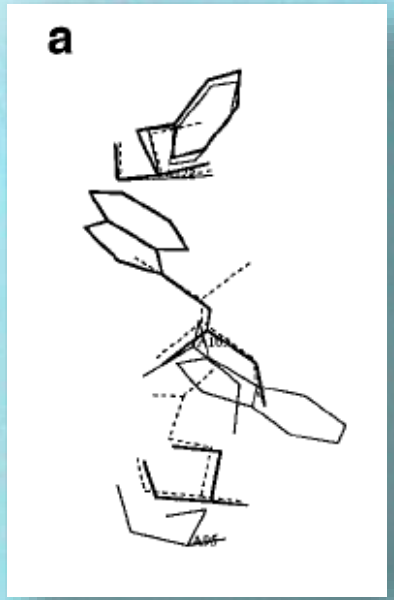

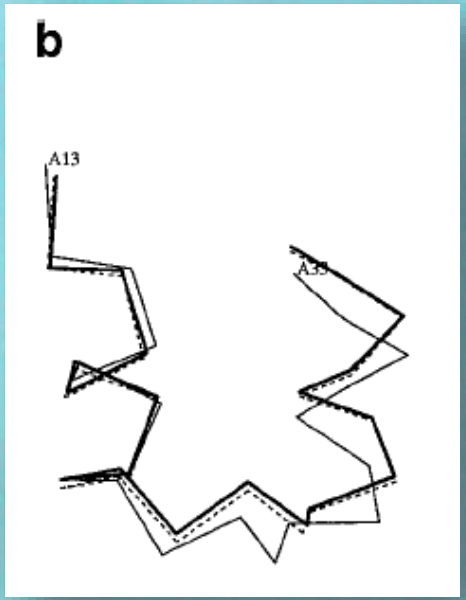

2. Сдвиги в корректно выровненных участках

Сравнение участка кристаллической структуры мышиного белка, связывающего ретиноевую кислоту с его моделью и с шаблоном.

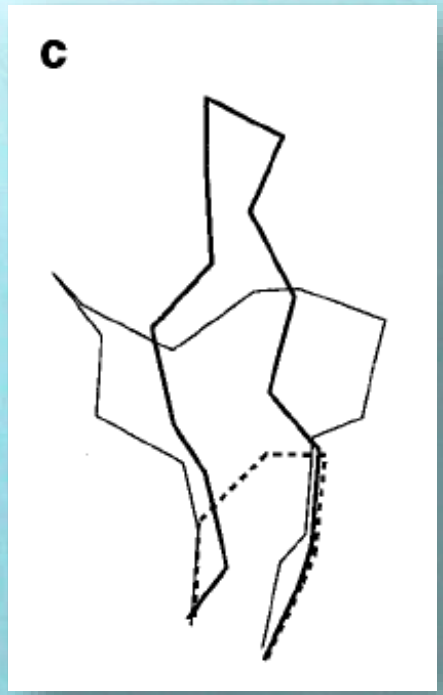

3. Ошибки в участках, для которых отсутствует шаблон

Показан контур Cα атомов остатков 112-117 кристаллографической структуры человеческого эозинофильного нейротоксина (тонкая линия), его модели (толстая линия), и шаблона – рибонуклеаза А (пунктир).

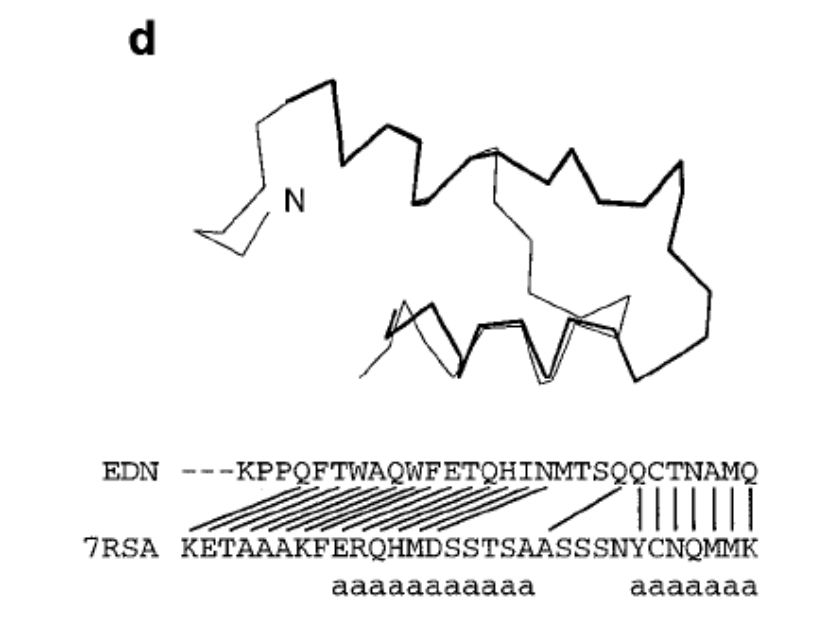

4. Ошибки из-за неправильного выравнивания

N-концевой участок токсина сравнивается с его моделью. Показан соответствующий участок выравнивания, линии показывают эквивалентные остатки

5. Неправильно выбранный шаблон

Оценка качества моделей

«Качество» модели (близость к нативной структуре) определяет ее пользу

- Качество выравнивания: функционально и структурно консервативные остатки
- Проверка стереохимии аминокислотных остатков модели (≈карты Рамачандрана) — PROCHECK, WHATCHECK
- Оценка параметров «пространственного окружения» остатков и сравнение их с полученными на наборе экспериментальных структур — VERIFY3D, ProsaII

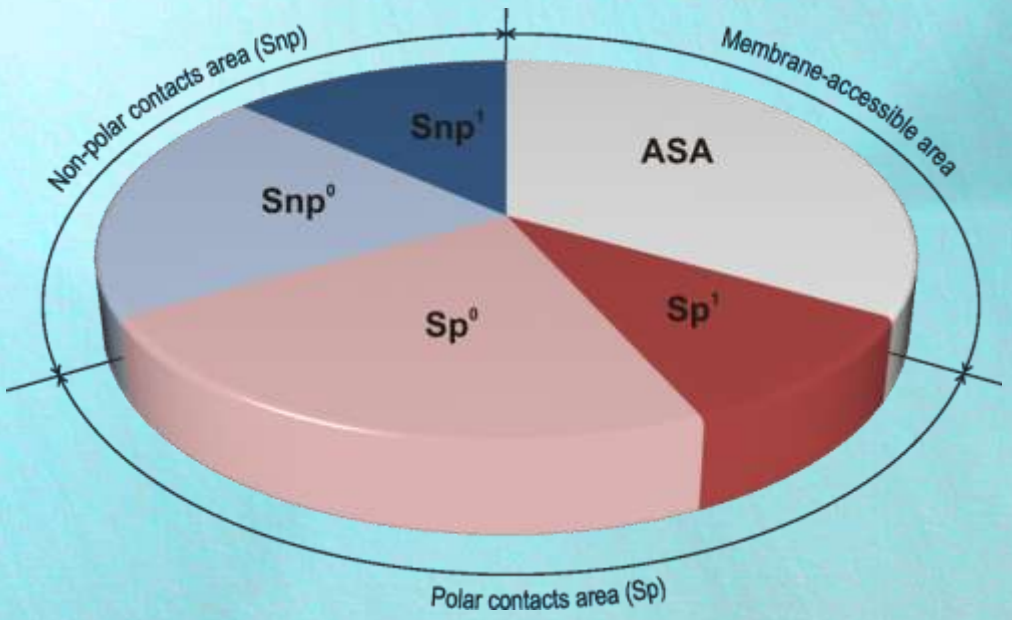

Характеристики молекулярной поверхности остатка

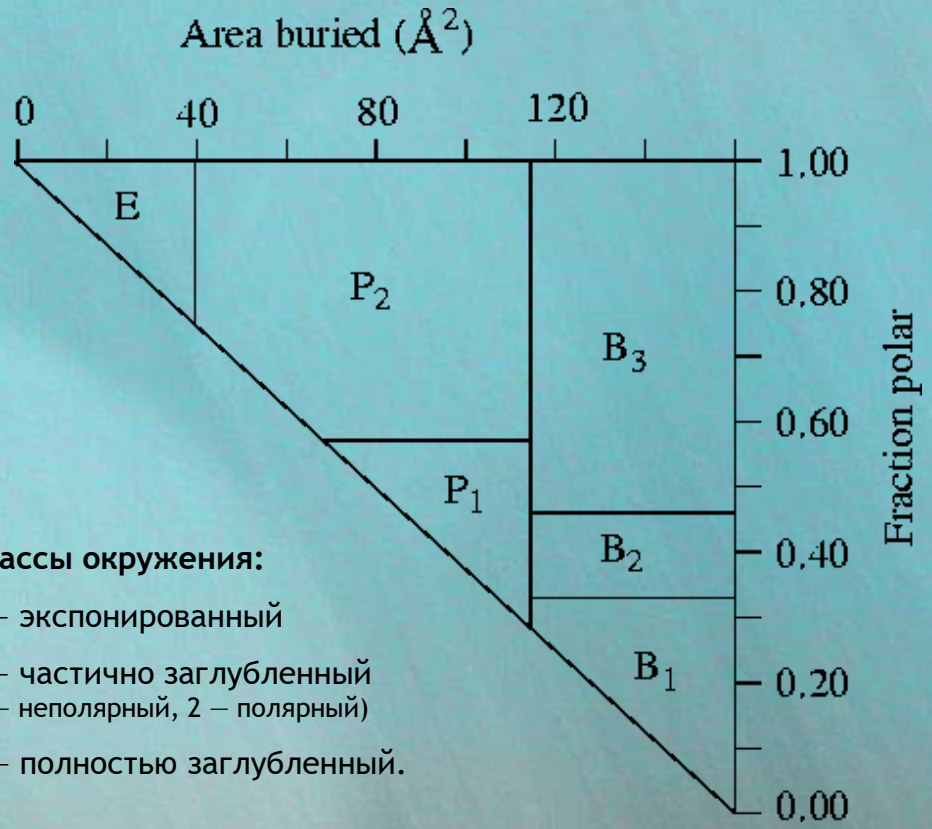

Классы окружения:

E — экспонированный

P — частично заглубленный
(1 — неполярный, 2 — полярный)

B — полностью заглубленный.

Мембранные белки устроены по-особенному

Растворимые глобулярные белки имеют гидрофобное «ядро» и полярную поверхность.
МБ устроены почти наоборот.

Поэтому для них требуется специальный подход

Анализ «качества» МБ: нужно выявить характерные для МБ особенности упаковки.

База структур МБ («обучающий набор»)

- Общее число структур МБ*: 617 (**234** уникальных). Это ~1% от всех известных структур.
- Структуры высокого разрешения (<3.5 Å, РСА) α-спиральных негомологичных (<40% идентичности) МБ: **85**. *Среди них:*
  - «Дыхательные» белки: 14 — Белки дыхательной цепи: Комплекс I (НАД·Н дегидрогеназа), комплекс II (фумарат редуктаза / сукцинат дегидрогеназа), комплекс III (комплекс цитохрома bc1), комплекс IV (цитохром-*c* оксидаза), убихинол-оксидаза, нитрат-редуктаза и т.д.
  - Бактериальные опсины: 5 — бактериородопсин, сенсорный бР, галородопсин, ксантородопсин
  - GPCR'ы: 4 — родопсин, β_2-адренорецептор, A2A-аденозиновый рецептор, родопсин кальмара
  - Ионные каналы: 18 — KvAP, KcsA, KirBac3.1 и Kir3.1 K^+-каналы, H^+/Cl^--обменники, Mg^{2+} транспортеры, механочувствительные каналы, ASIC, M2-канал, P_2X_4-канал и т.д.
  - Прочие каналы: 17
  - Аква- и глицеропорины: 6
  - Multi-drug efflux pumps и Major facilitator proteins: 4
  - Фотосинтетические белки (здесь не перечислены)
  - ABC-транспортеры: 6
  - АТФазы: 4

  и другие

* — *на март 2010 г.*

Оценивающая функция для МБ

I. Оптимальное расположение ТМ-доменов в мембране. Границы ТМ-домена.

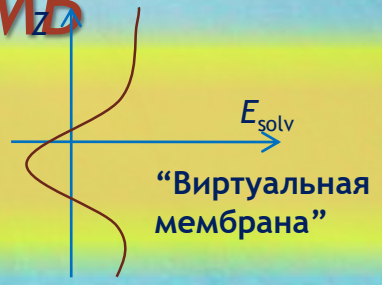

II. Статистика по контактам остаток–остаток и остаток–мембрана

Параметры упаковки белка

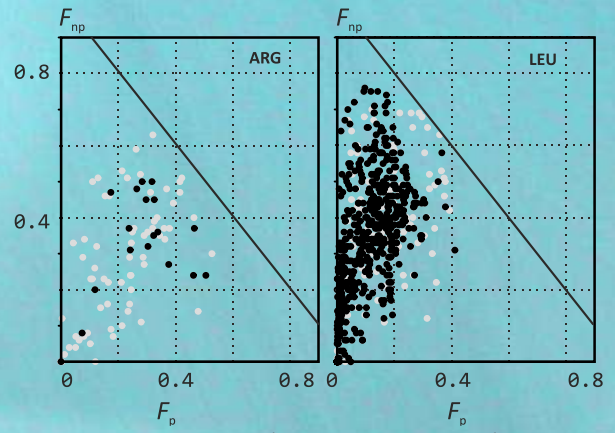

Упаковка “обучающего набора” (F_p×F_{np})

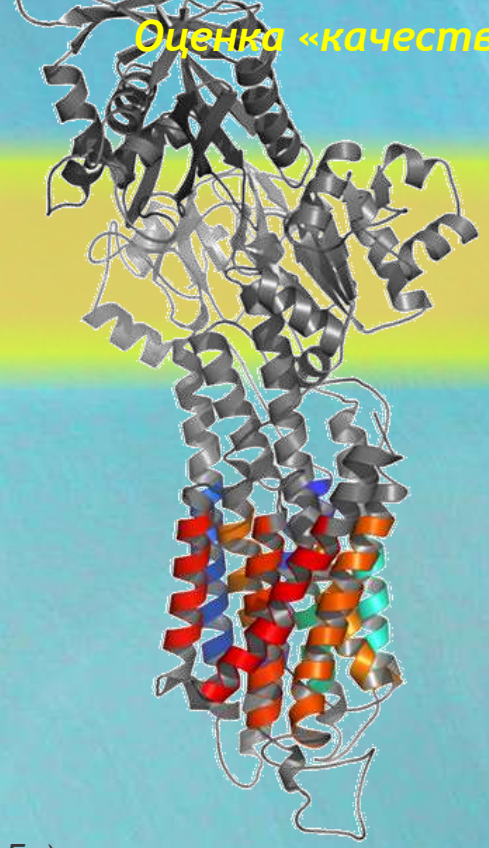

III. Классы 3D-окружения белок–мембрана. «Предпочтения» остатков

“Совместимость” остатка i с классом окружения j:

$$ОФМБ_{ij} = \ln {}^{P_{ij}}/_{P_j},$$

где P_{ij} — частота остатков i в классе j, а P_j – «заселённость» класса j.

Протабулированная “ОФМБ”:

	Класс окружения				
	1	2	3	4	5
ALA	0.05	-1.20	-0.91	0.93	0.82
ARG	-1.79	-1.58	-0.74	-0.01	1.90
ASN	-1.21	-0.71	0.93	-1.22	0.60

…

ОФМБ: оптимизация моделей

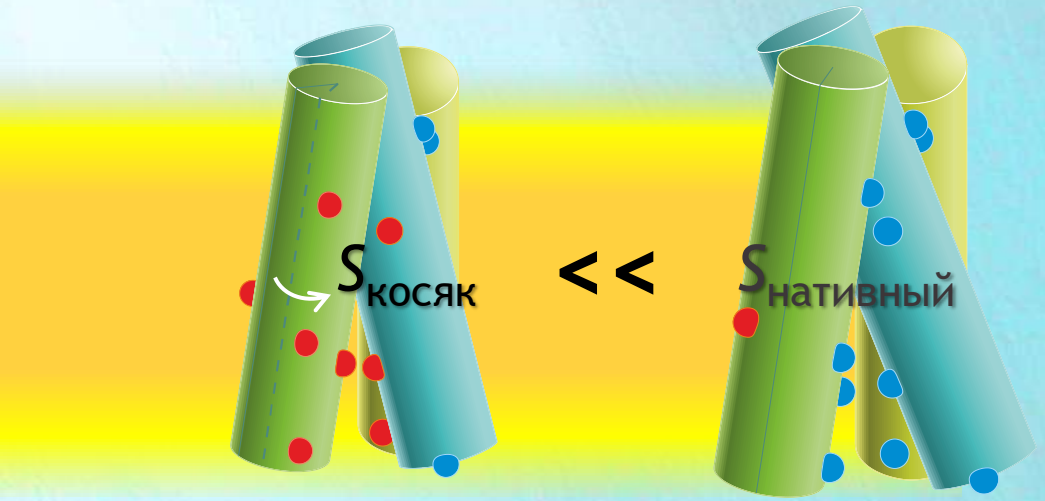

– упаковка неоптимальна
– упаковка близка к нативной

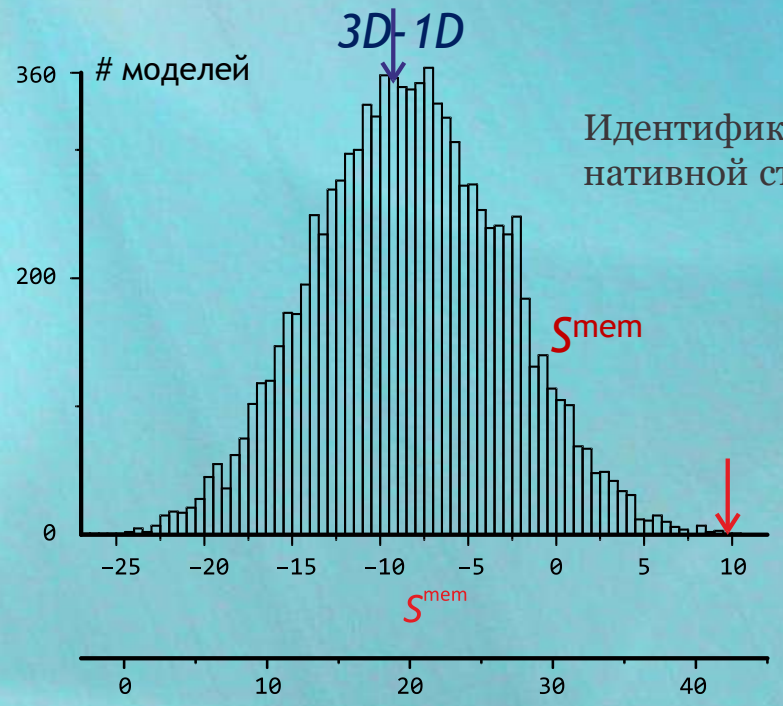

3D-1D Score (for water-soluble proteins; D. Eisenberg)

Идентификация моделей, близких к нативной структуре

Оптимальный выбор «шаблона».
Хорошая корреляция ОФМБ×СКО.

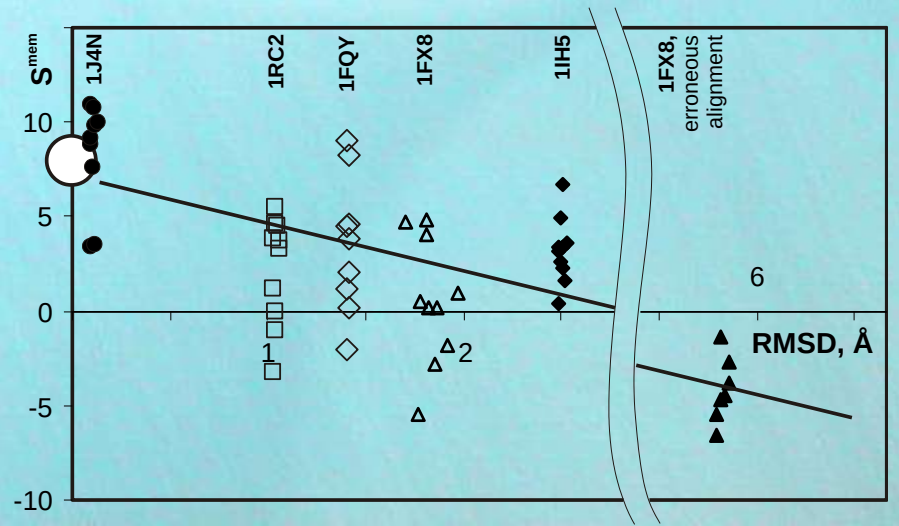

☑ Идентификация ошибок в выравнивании при построении моделей

Chugunov A.O. *et al.* (2007). A method to assess packing quality of transmembrane α-helices in proteins. I. Parameterization using structural data. *J. Chem. Inf. Model.* **47**, 1150-1162 и … II. Validation by “correct vs. misleading” test. *J. Chem. Inf. Model.* **47**, 1163-1170.

Модели аквапорина-1, простроенные на основе различных шаблонов

Моделирование рецептора VIPR1 (GPCR B)

Работа проводилась в рамках проекта по дизайну пары «неорецептор» VPAC1 / «неолиганд» для терапии дендритными клетками воспалительных и аутоиммунных заболеваний

GPCR семейства B –

Рецепторы пептидных гормонов (≈15 членов)

- Крупный N-концевой (внеклеточный) домен «захватывает» пептидный лиганд из раствора
- Чрезвычайно низкое сходство последовательности с рецепторами GPCR A в TM-домене; однако семиспиральная укладка сохраняется
- Видимо, отличный от GPCR-A механизм активации рецептора

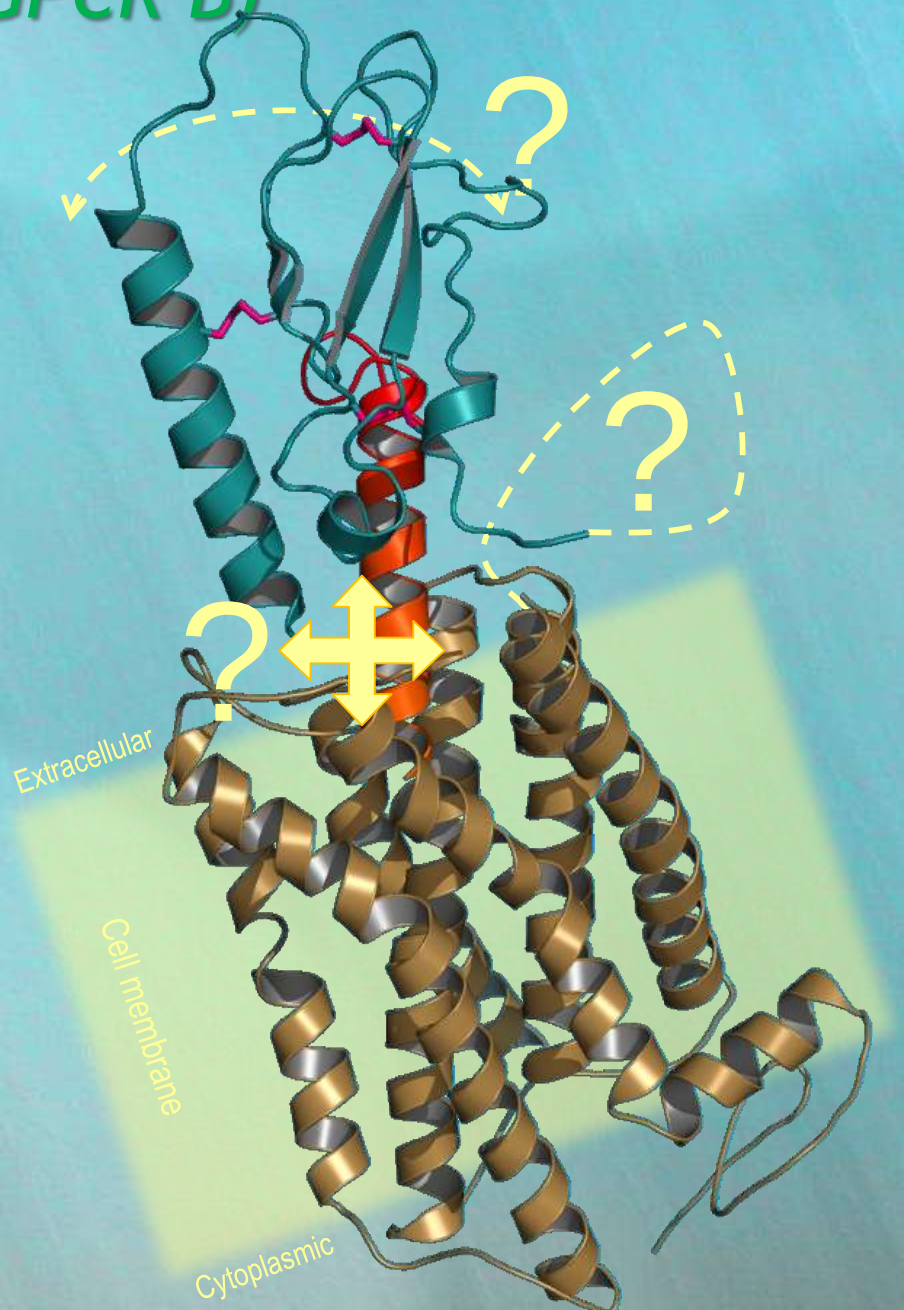

GPCR A – шаблон для TM-домена:

- Родопсин («темновая» форма или связывающая G-белок)
- β_1- и β_2-адренорецепторы
- Аденозиновый рецептор

GPCR B внеклеточный домен: PACR-PACAP, GIPR-GIP, GLP1R-Exendin-4, mCRFR2β-Astressin, PTH1R (engineered)-PTH

3D-модель рецептора VIPR1

Проблемы:

- Идентичность с любым доступным шаблоном очень низка (~10–12%): «сумеречная зона»
- Аминокислотные выравнивания GPCR A-B в литературе драматически расходятся: проблема а/к выравнивания для GPCR B особенно актуальна

TM1

```
     YTIGYGLSLATLLVATAILSLFR      (1)
       YTIGYGLSLATLLVATAILSLFR    (2)
      YTIGYGLSLATLLVATAILSLFR     (3)
         YTIGYGLSLATLLVATAILSLFR  (4)
WQFSMLAAYMFLLIMLGFPINFLTLYVTVQ    (opsd)
```

TM2

```
RNYIHMHLFISFILRAAAVFIKD           (1)
    RNYIHMHLFISFILRAAAVFIKD       (2)
   PLNYILLNLAVADLFMVFGGFTTTLYTSLH (opsd)
```

TM3

```
 AAMVFFQYCVMANFFWLLVEGLYLYTLL     (single)
NLEGFFATLGGEIALWSLVVLAIERYVVV     (opsd)
```

TM4

```
      KYFWGYILIGWGVPSTFTMVWTIAR   (1)
KYFWGYILIGWGVPSTFTMVWTIAR         (4)
      NHAIMGVAFTWVMALACAAPPLV     (opsd)
```

TM5

```
        SLWWIIKGPILTSILVNFILFICIIR(1)
       SLWWIIKGPILTSILVNFILFICIIR (3)
SLWWIIKGPILTSILVNFILFICIIR        (4)
     NESFVIYMFVVHFIIPLIVIFFCYGQ   (opsd)
```

TM6

```
  RLARSTLLLIPLFGVHYIMFAFFPDN  (single)
EKEVTRMVIIMVIAFLICWLPYAGVAFY  (opsd)
```

TM7

```
  MVFELVVGSFQGFVVAILYCFLNGEVQ (single)
IFMTIPAFFAKTSAVYNPVIYIMM      (opsd)
```

4×2×1×2×3×1×1=48 вариантов

Какое выравнивание или комбинация лучше?

Необходимо использовать совместно разные подходы:

- Оптимальное положение функциональных остатков
- “Вариабельная” организация МБ
- Гидрофобные стороны α-спиралей — в мембрану
- Общие принципы упаковки МБ

ОФМБ

«Референсные» остатки в каждом подсемействе

Функционально важные остатки для рецептора VIPR1

ТМ-домен VIPR1: «итоговое» выравнивание

```
TM1 OPSD:  WQFSMLAAYMFLLIMLGFPINFLTLYVTVQHKKLR
    VIPR1: SVKTGYTIGYGLSLATLLVATAILSLFRKLHC---

TM2 OPSD:  TPLNYILLNLAVADLFMVFGGFTTTLYTSLHGY--
    VIPR1: -TRNYIHMHLFISFILRAAAVFIKDLALFDSGESD

TM3 OPSD:  -FVFGPTGCNLEGFFATLGGEIALWSLVVLAIERYVVVCKPM
    VIPR1: QCSEGSVGCKAAMVFFQYCVMANFFWLLVEGLYLYTLLAV--

TM4 OPSD:  SNFRFGENHAIMGVAFTWVMALACAAPPLVGWSRYIPEGMQCSCG
    VIPR1: -SFFSERKYFWGYILIGWGVPSTFTMVWTIARIHFEDYG------

TM5 OPSD:  IDYYTPHEETNNESFVIYMFVVHFIIPLIVIFFCYGQLVFTVKEA-
    VIPR1: --------CWDTINSSLWWIIKGPILTSILVNFILFICIIRILLQK

TM6 OPSD:  AAQQQESATTQKAEKEVTRMVIIMVIAFLICWLPYAGVAFYIFTH
    VIPR1: LRPPDIRKSDSSPYSRLARSTLLLIPLFGVHYIMFAFFPDNF---

TM7 OPSD:  QGSDFGPIFMTIPAFFAKTSAVYNPVIYIMMNKQFRNCMVTTLCCGK
    VIPR1: ----KPEVKMVFELVVGSFQGFVVAILYCFLNGEVQAELRRKWRRW-
```

Корректность выбранного выравнивания подтверждается значениями ОФМБ модели, а также динамически-усредненным значением ОФМБ для «итоговой» и «рабочих» моделей

3D-модель TM-домена VIPR1

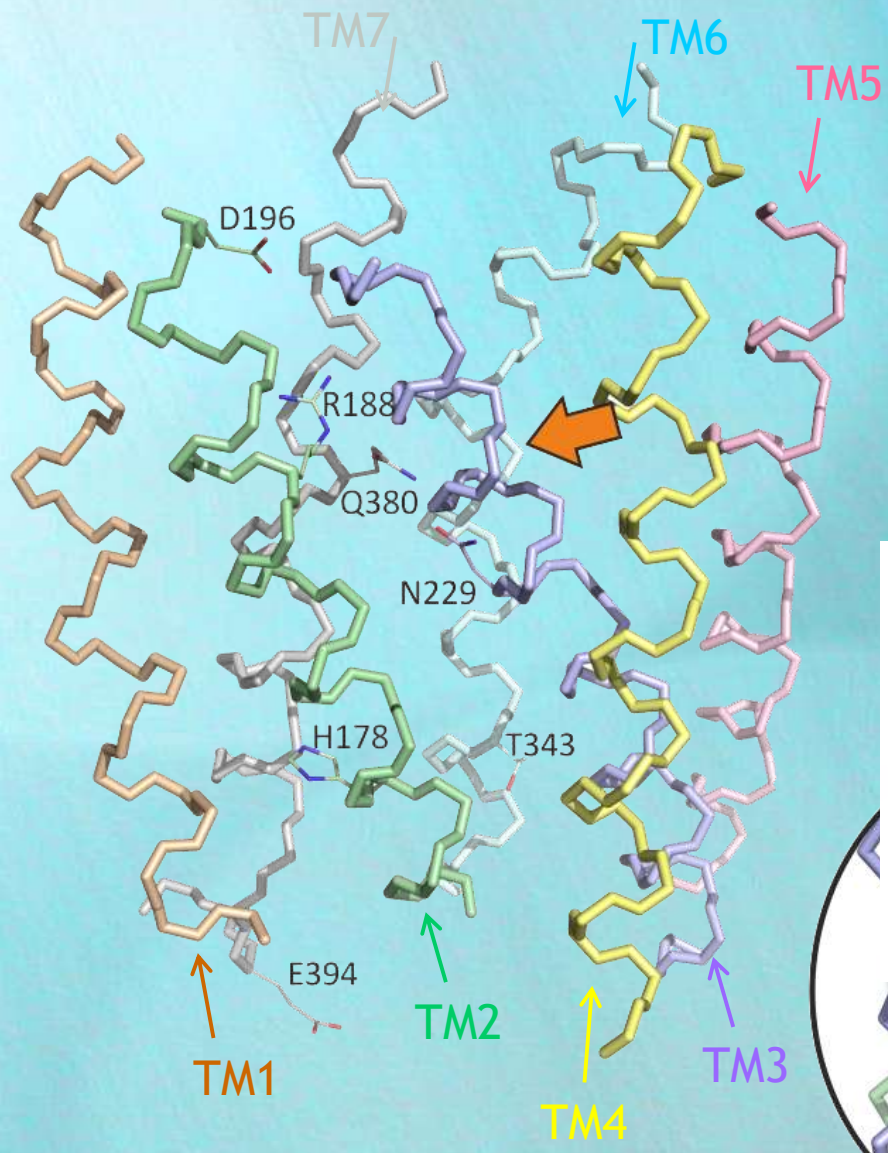

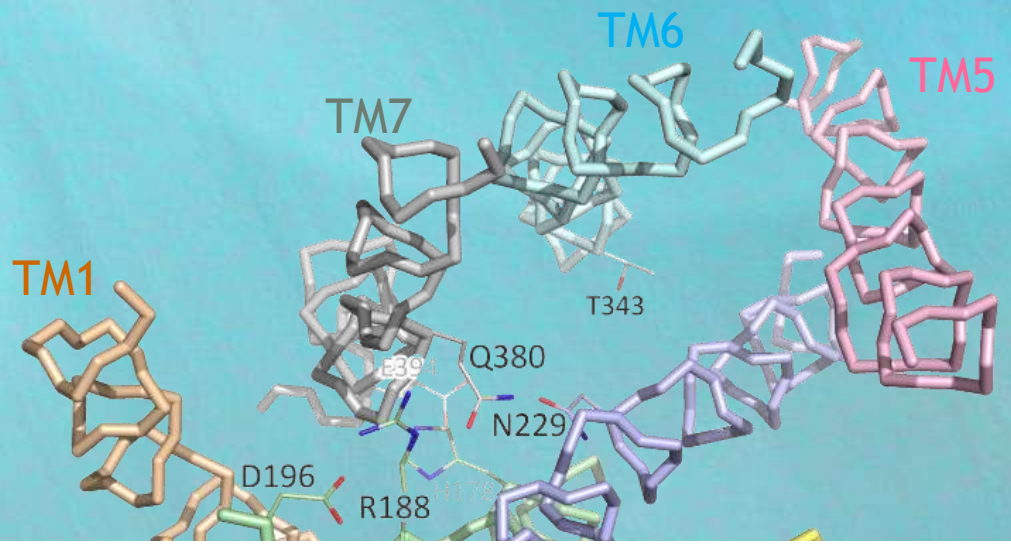

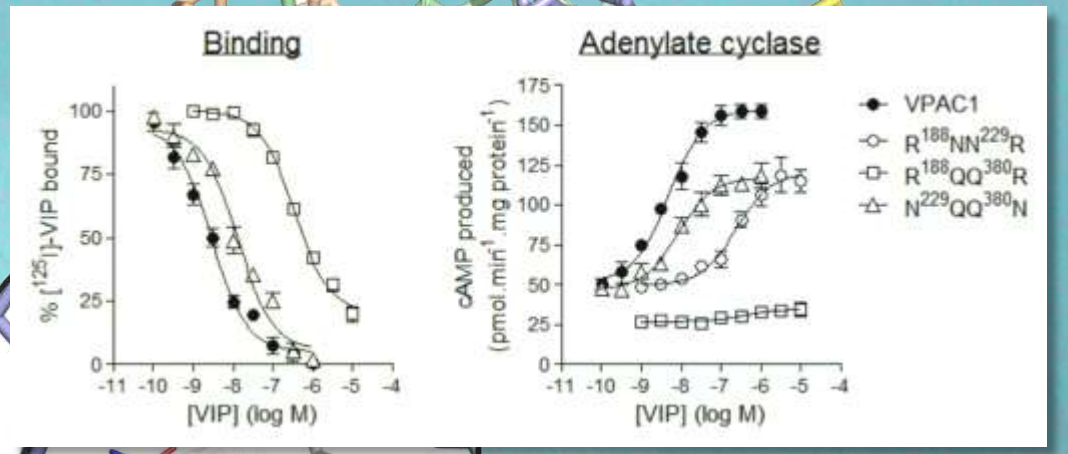

Линейная «триада»

R188@TM2–Q380@TM7–N229@TM3

Chugunov A.O. *et al.* (2010). Mol. Pharm. **78**, 394-401

«Профпригодность» 3D-моделей белков

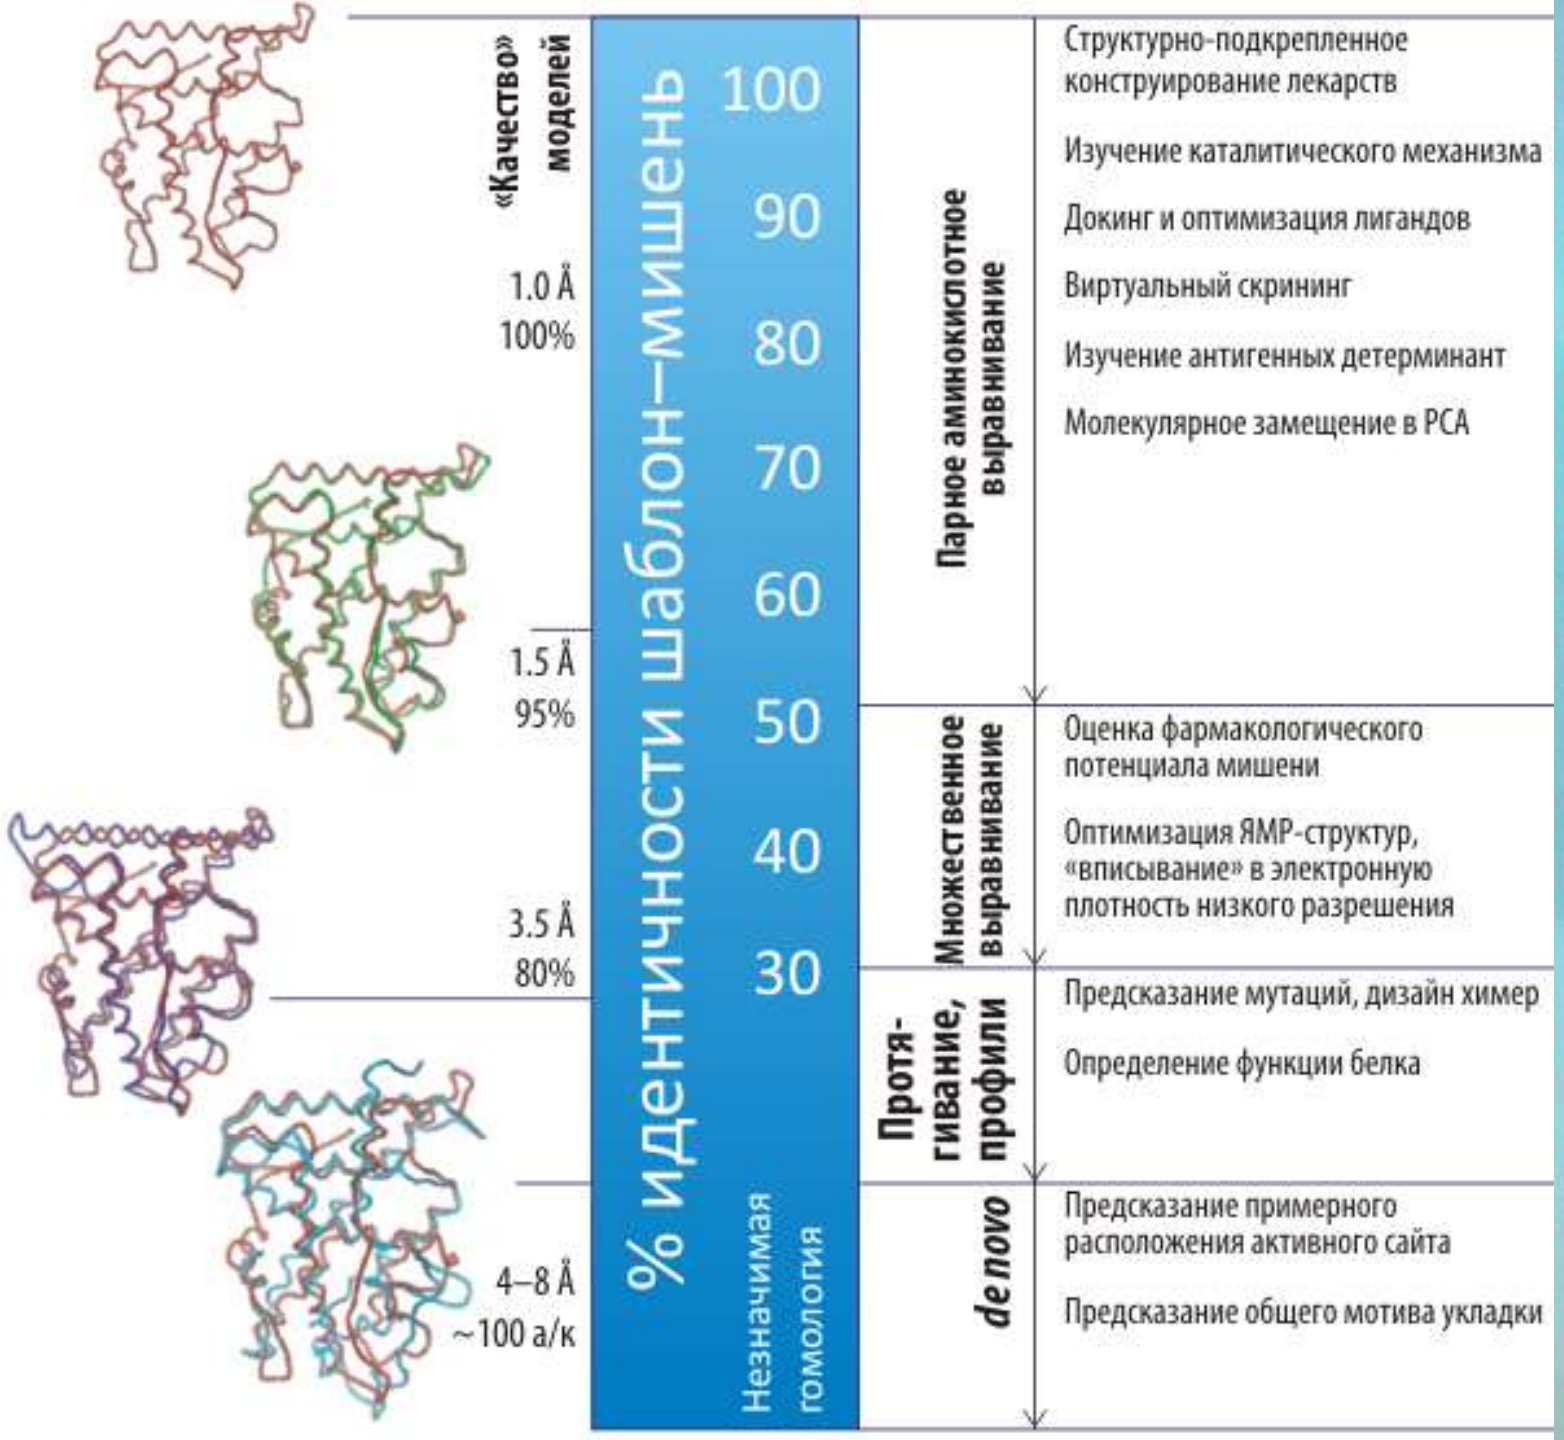

В левой части рисунка — наложенные структуры ядерных рецепторов в зависимости от идентичности к прогестероновому рецептору:

- 54% — глюкокортикоидный рецептор
- 24% — эстрогеновый рецептор α
- 15% — рецептор трийодтиронина

Применение 3D-моделей белков в драг-дизайне

Выбор мишени → **Валидация мишени** → **Идентификация соединения-«прототипа»** → **Оптимизация прототипа** → **Клинические тестирования производство**

Выбор мишени

Проектирование точечных мутантов

Валидация мишени

Оценка фармакологического потенциала из анализа сайтов связывания

Синтез соединений для проверки биологической функции

Идентификация соединения-«прототипа»

Высокопроизводительный докинг

Дизайн библиотек соединений сфокусированного или широкого спектра действия

Планирование *in vitro*-контрольных экспериментов и проверок на модельных животных

Оптимизация прототипа

Предсказание характеристик связывания и структуры комплексов рецептор–лиганд

Оптимизация структуры и характеристик прототипа

Предсказание токсичности, фармакокинетики и взаимовлияния с другими препаратами

Предсказание структуры и общество

Дух соревнования: «Экспертиза методов по предсказанию структуры белка́» (CASP, Critical Assessment of Techniques for Protein Structure Prediction)

- *Цель:* оценить прогресс в области теоретического предсказания строения белков
- *Периодичность:* раз в два года
- *Мишени:* как правило, «трудные» случаи, не имеющие близкородственных структурных гомологов
- *Результаты:* Люди (эксперты) справляются с задачей намного лучше, чем сервера-«предсказатели» из-за использования своего рода интуиции.

Игра в фолдинг

http://fold.it

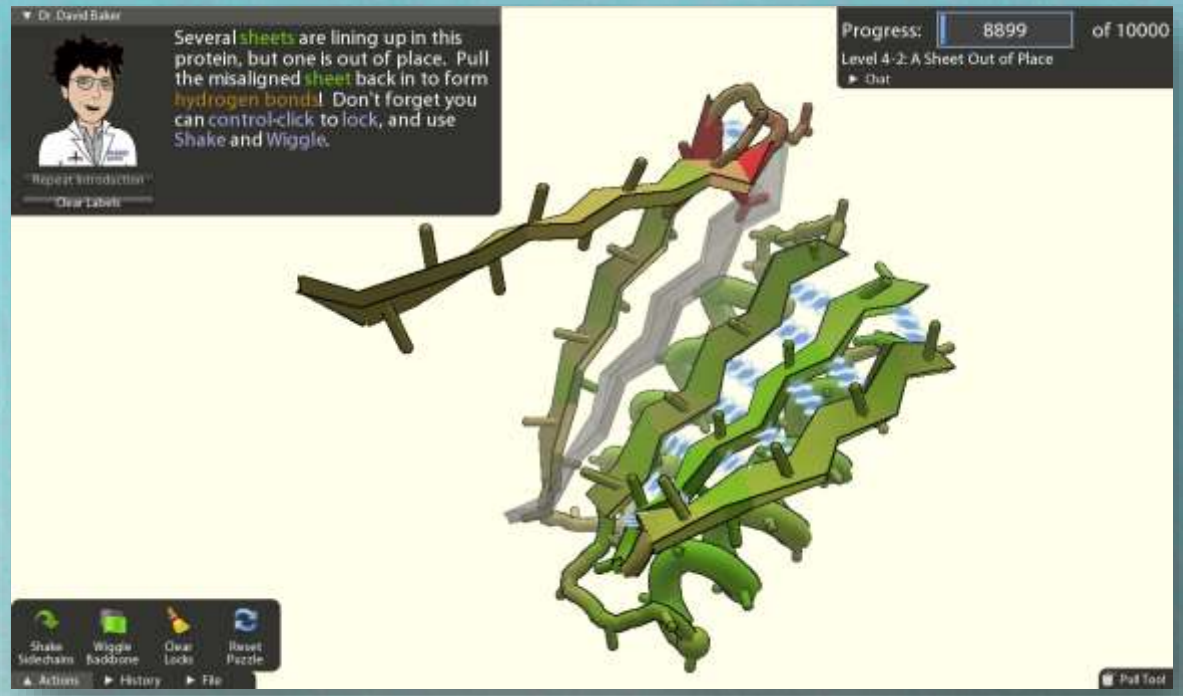

AlphaFold: тятя, тятя, нейросети заменили продавца!

- В соревновании CASP13 (2018) «новичок» AlphaFold (v. 1) внезапно показал самую высокую точность предсказаний: ⟨GDT⟩ ≈ 75%

- Два года спустя (в CASP14) шаблон был вторично порван: AF2 показал среднее качество моделей ⟨GDT⟩ ≈ 90%, выдавая «атомную точность» и сильно оторвавшись от конкурентов

- AF2 строится на нейросети-«трансформере», предсказывающей 3D-структуру белков напрямую из последовательности, без непосредственного использования шаблона*

- Вместе с EMBL выпущена AlphaFold Database, содержащая 200M (!) предсказаний

- Тренировка на 170K 3D-структур белков из PDB и содержит 170M параметров

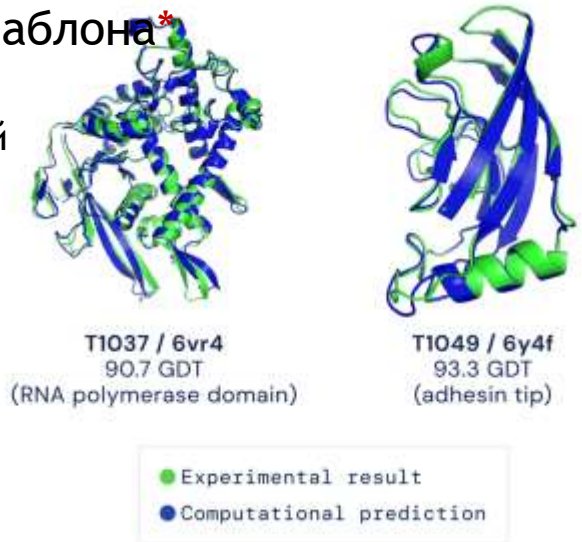

Важные аспекты:

- * Шаблон(ы) используются, хотя они не обязательны

- Критически важно использование множественных выравниваний (MSA) с гигантскими метагеномными базами, которых не было еще 10 лет назад

AlphaFold: тятя, тятя, нейросети заменили продавца!

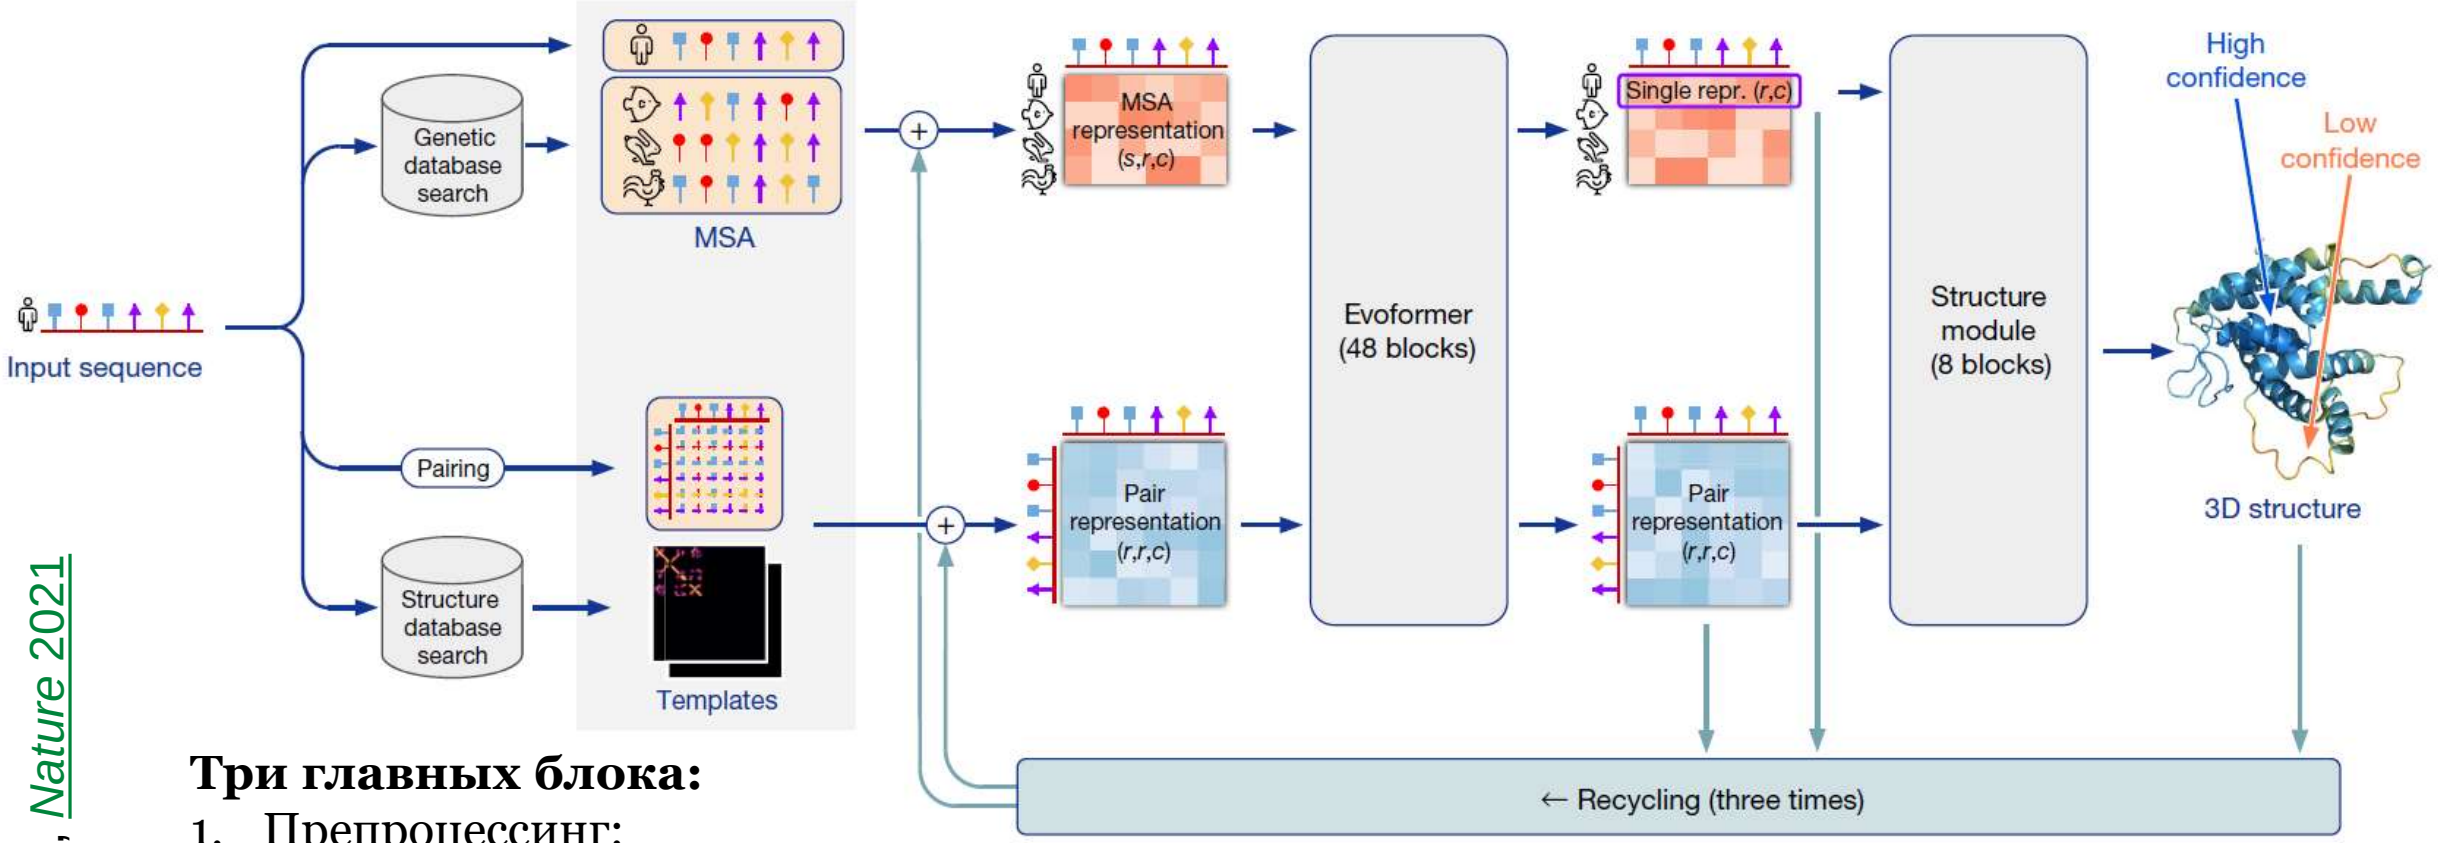

Jumper *et al.*, Nature 2021

Три главных блока:

1. Препроцессинг:
   - Построение MSA в «мета-базах» (“single representation”) и
   - Поиск возможных шаблонов в PDB (стартовая точка для “pair representation”)
2. Evoformer ×48 — главный трансформер 1D- и 2D-данных (взаимно обогащает)
3. Structure module ×8 — генерирует «конечную» (end-to-end) 3D-модель и «качество» (pLDDT)
4. Три-четыре «оборота колеса», повышающих реалистичность модели

AlphaFold Database

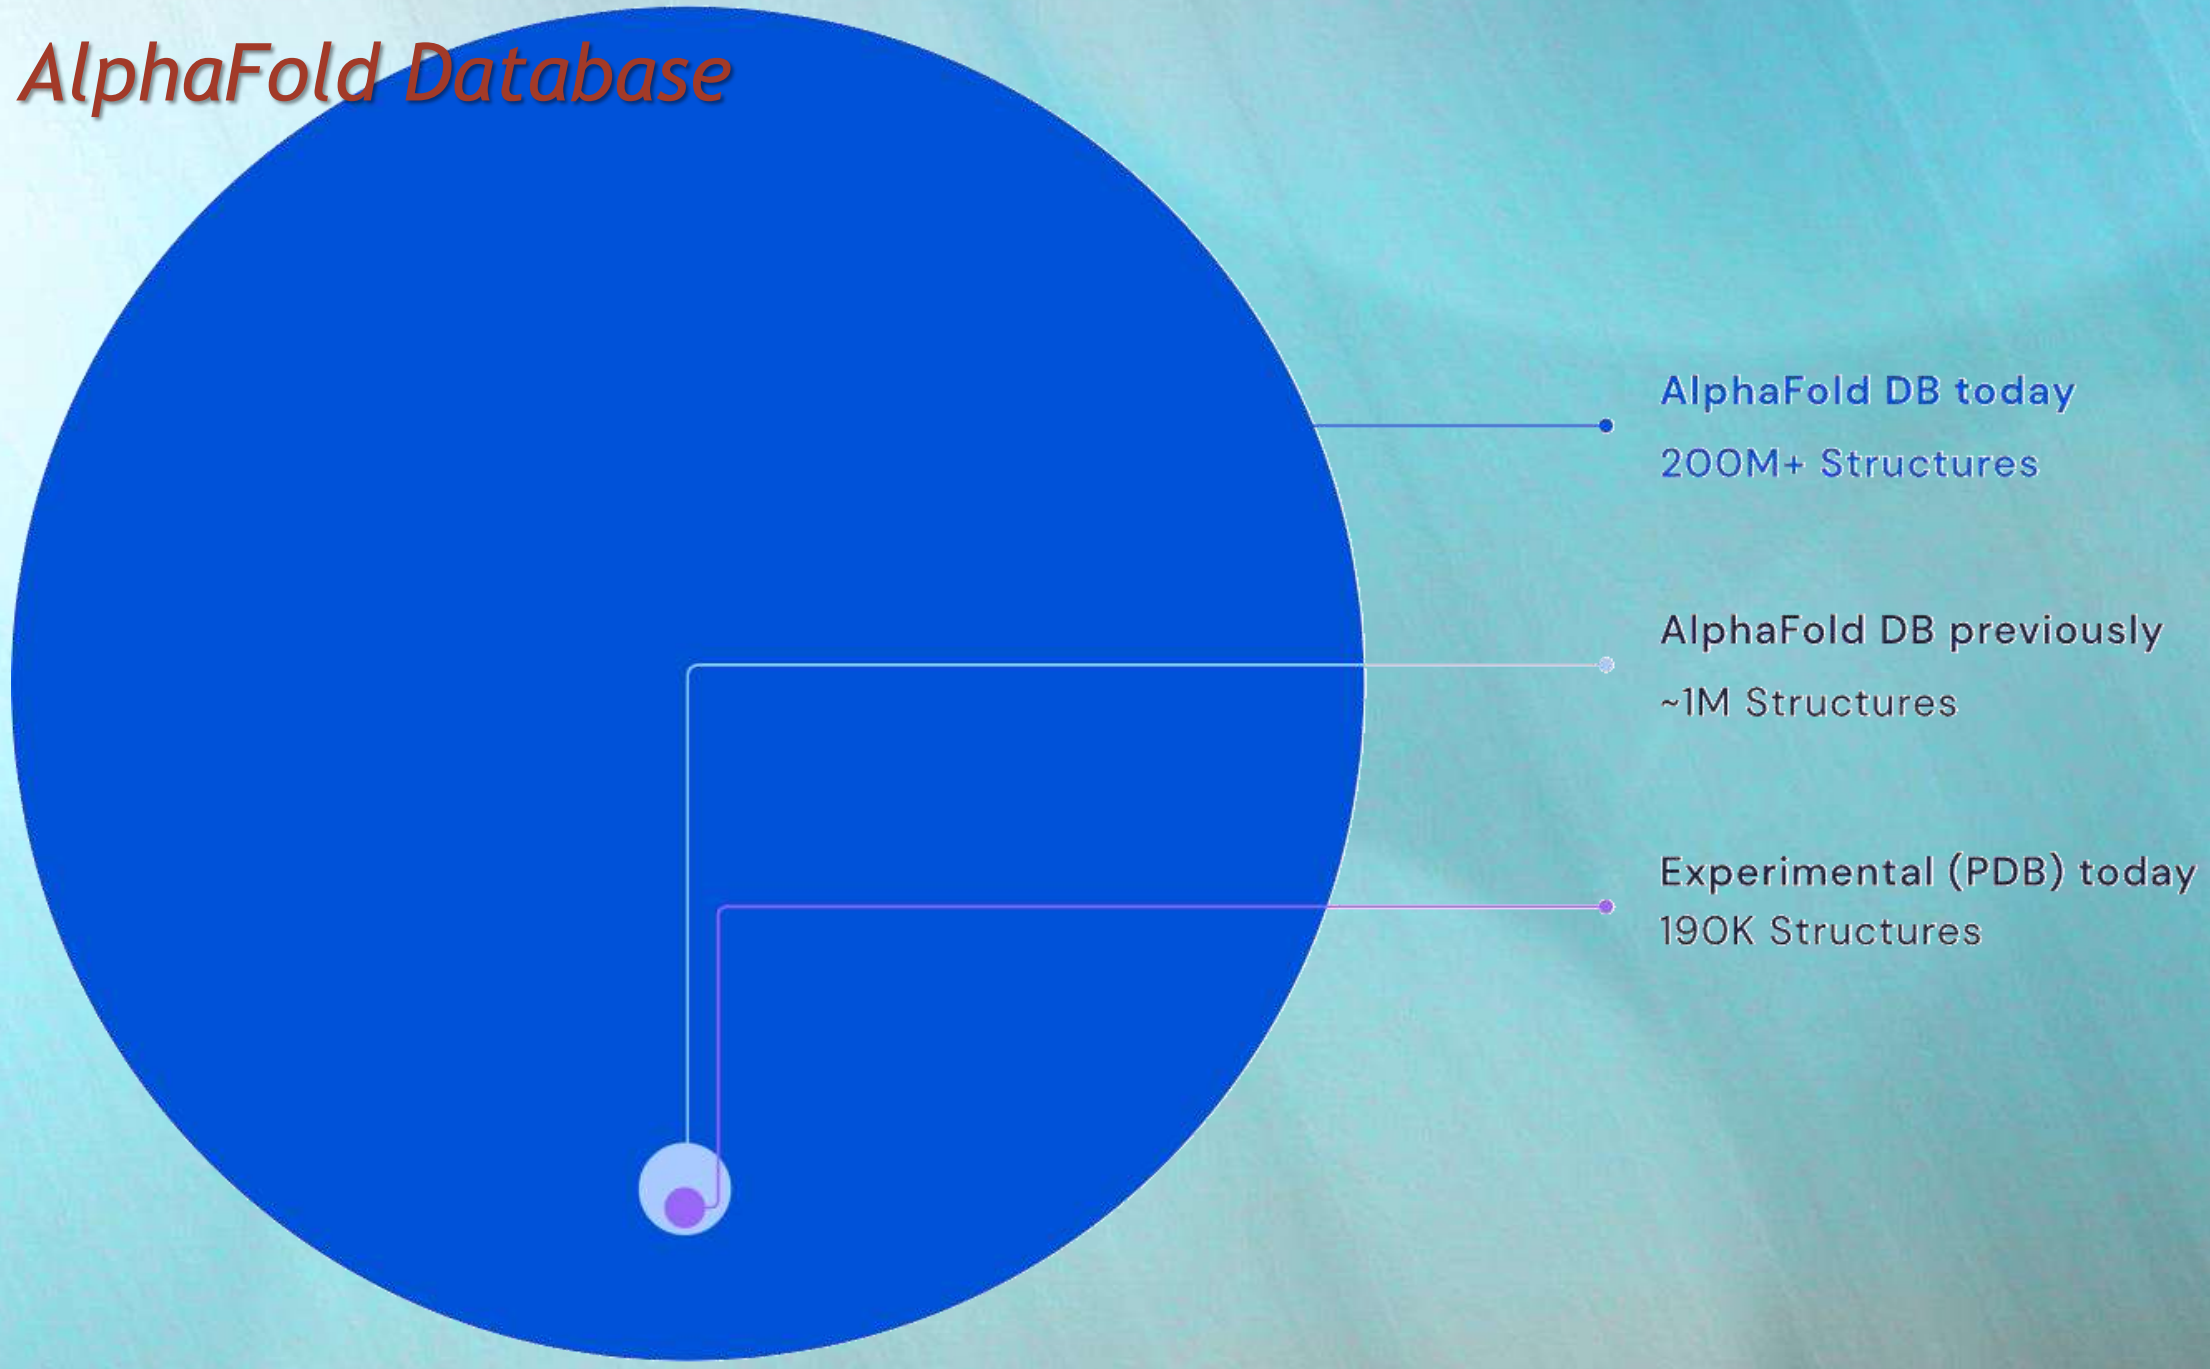

AlphaFold reveals the structure of the protein universe

Нельзя просто так взять и придумать такую архитектуру

Forbes по случаю вручения Бейкеру, Хасабису (*слева*) и Джамперу (*справа*) премии Breakthrough Prize'2023

- Самая сложная наша система: 32 алгоритма, 60 страниц саплемента
- “No silver bullet” — продвинутый инжиниринг, огромные вычислительные мощности и много-много труда
- 20 человек разных специальностей фигачили пять лет
- Обучение заняло две недели на 128 TPU (аналог ~1000 GPU)

Выводы

- Современная техника молекулярного моделирования позволяет «заглядывать» в наиболее ранние этапы биологических процессов
- Такая имитация представляет не только фундаментальный интерес, но и служит основой для рациональной модификации и дизайна биологических молекул с практически важными свойствами
- Наиболее крупные белковые молекулы, в случае отсутствия экспериментально определенной пространственной структуры, пока приходится моделировать на основе «шаблонов»
- …но ИИ быстро отвоевывает «поляну»
- Статистические подходы позволяют оптимизировать 3D-структуру крупных белков более эффективно, чем моделирование на основе силовых полей
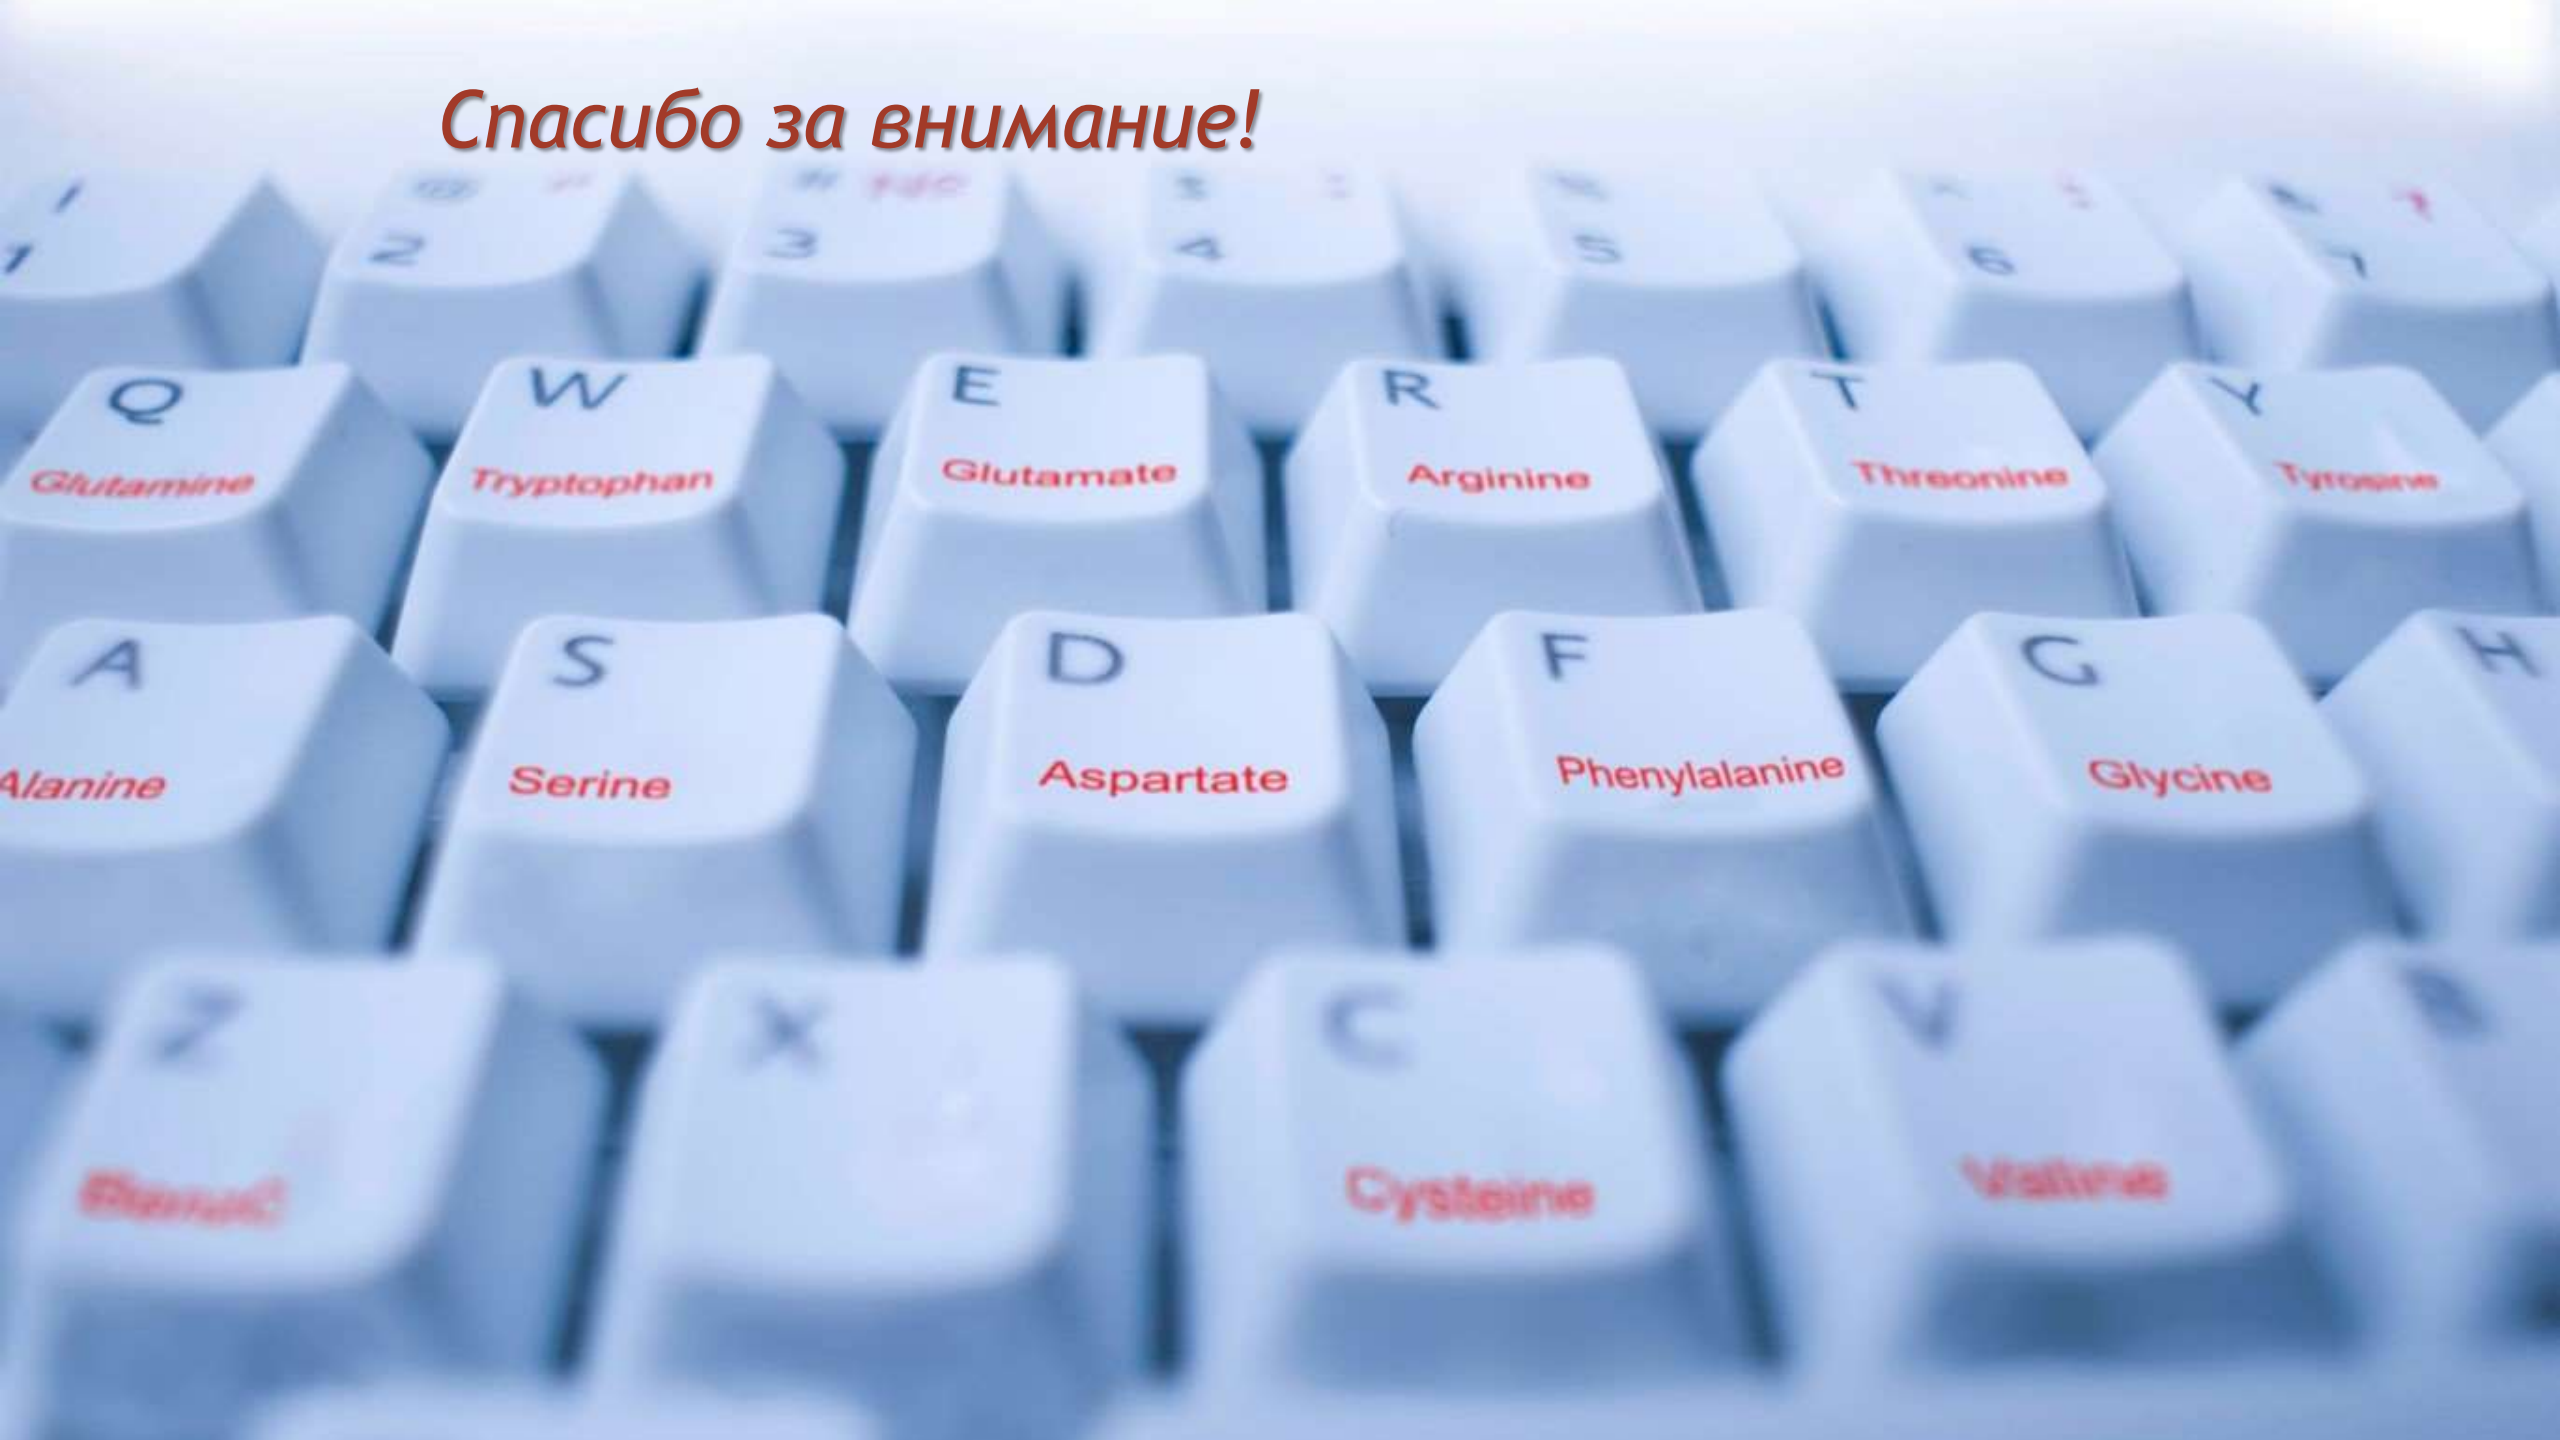
Спасибо за внимание!